

01 SKE

ČÁST-I
2h/týden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY !

VÁCLAV KŮS , KM FYFI ČVUT

© VK 2023 (KM FYFI ČVUT)


$T \geq 0$ doba života, do poruchy, ...

$$\underline{R_T(t)} = 1 - F_T(t) = P(T > t)$$

$$\underline{MTTF_T} = ET = \mu = \int_0^{\infty} R_T(t) dt$$

! FR (failure rate) INTENZITA PORUCH

$$\lambda_T(t) = f_T(t) / R_T(t)$$



$$\lambda_T(t) \cdot \Delta t \approx P(t < T \leq t + \Delta t | T > t)$$

! CFR:

$$\underline{L_T(t)} = \int_0^t \lambda_T(t') dt' = \int_0^t \frac{d}{dt} (-\ln R_T(t)) dt$$

! CFR: $\Lambda_T(t) = \int_0^t \lambda_T(t') dt' = \int_0^t \frac{d}{dt} (-\ln R_T(t)) dt$

$$\lambda_T \leftrightarrow \Lambda_T \leftrightarrow R_T(t) = e^{-\int_0^t \lambda_T(t') dt'} \leftrightarrow f_T$$

$\Downarrow$ $R(x|t) = P(T > t+x | T > t) = R_T(t+x) / R_T(t)$

$MRL(t) = \int_0^\infty R(x|t) dx = \frac{1}{R_T(t)} \cdot \int_t^\infty R_T(x) dx$

$$MRL(t) \triangleq \mu(t); \quad \mu(0) = MTTF$$

Studie: $g_T(t) = \frac{MRL(t)}{MTTF}$ (% podíl)
průběhu

RODINY DISTRIBUTUCÍ ~ TS

IFR model : $\lambda_T(t)$ rostoucí / Λ_T konvexní!
DFR : λ_T klesá / Λ_T konkávní!

$$\text{ma } 0 \leq t < t_F = F_T^{-1}(1)$$

$$\frac{d}{dt} \lambda(t) \stackrel{\text{dif.}}{=} \frac{d}{dt} \left(\frac{d}{dt} \Lambda(t) \right) \stackrel{\text{dif.}}{=} \frac{d^2}{dt^2} (-\ln R_T(t))$$

IFRA / DFRA : $\frac{\Lambda_T(t)}{t}$ roste / klesá, $t \geq 0$

!NBU (New Better than Used) :

$$R(x|t) \leq R(x), \quad t \geq 0; x \geq 0$$

! NWU: $R(x|t) \geq R(x), \quad t \geq 0; x \geq 0$

NBUE (NBU in Expectation) if $\exists \mu = \text{MTTF}$ a

$$\text{MRL}(t) \leq \mu, \text{ then } g_T(t) = \frac{\text{MRL}(t)}{\mu} \leq 1, \quad t \geq 0$$

NWUE: $\text{MRL} \geq \mu, \text{ then } g_T(t) \geq 1, \quad t \geq 0$

$$V: \text{IFR} \Rightarrow \text{IFRA} \Rightarrow \text{NBU} \Rightarrow \text{NBUE}$$

$$\text{DFR} \Rightarrow \text{DFRA} \Rightarrow \text{NWU} \Rightarrow \text{NWUE}$$

CENZOROVÁNÍ DAT (KLINICKÝ VÝZKUM)

BAYESovské metody ve SKE

VK © 2023 KM
FJFI ČVUT

$\pi(\theta)$ apr. + data $\mathbf{z} \sim \pi \sim f(\mathbf{z}|\theta)$

$$\text{update } \pi(\theta|\mathbf{z}) = \frac{f \cdot \pi}{\int f \cdot \pi d\theta} \Rightarrow \hat{\theta}_B = \begin{cases} L_1 \\ L_2 \\ L_{\{0,1\}} \\ \dots \end{cases}$$

Užití: nestabilita výroby
přijímka poškození zásilky
pacienti - update ; expert vs. minulost.

NONINVARIANT
 $\hat{\pi}_B(\theta)$

! Sekvencní Bayes: $\pi(\theta), \pi \rightarrow \pi(\theta|\mathbf{z}) \rightarrow \hat{\theta}_B$

$\tilde{\pi}_1(\theta) = \pi(\theta | t) + \text{nová data } \tilde{\pi}_1$ (nové poruchy,
nový medic. přístroj, ...)

$$\tilde{T}_1 \sim \tilde{f}_1(\tilde{t}_1 | \theta)$$

update $\tilde{\pi}_1(\theta | \tilde{t}_1) \Rightarrow \tilde{\theta}_B = \dots$

$$\tilde{\tilde{\pi}}_2(\theta) = \tilde{\pi}_1(\theta | \tilde{t}_1) + \tilde{\tilde{\pi}}_2 \sim \tilde{f}_2(\tilde{t}_2 | \theta)$$

update $\tilde{\tilde{\pi}}_2(\theta | \tilde{t}_2) \Rightarrow \tilde{\tilde{\theta}}_B = \dots$

EMPIRICKÝ BAYES: $\pi(\theta; \lambda)$; $m(t; \lambda) = \int f \cdot \pi d\theta$
HIERARCHICKÝ B: $\pi(\theta) = \int \pi(\theta | \theta_1) \pi(\theta_1) d\theta_1 \dots$

BAYES. interval spolehlivosti nebo HPDR

BAYESOVSKÁ SPOLEHLIVOST: $\hat{R}_B, \hat{\lambda}_B, \hat{L}_B, \hat{MRL}_B$

PREDIKCE SPOLEHLIVOSTI

VK © 2023 KM
FJFI ČVUT

$(T_j)_1^n$ iid R_T klas. stat. $\hat{\theta}_{ML}, \hat{\theta}_{MM}, \dots, \hat{\theta}_{UMVUE}$

$$\Rightarrow \hat{f}_T, \hat{R}_T, \hat{\lambda}_T, \hat{L}_T(t, \hat{\theta}_{ML})$$

$$\Rightarrow \hat{P}(T_{n+1} > t | \#_{data}) \text{ nebo } CI_{1-\alpha} \dots$$

$$\pi(\theta) + \text{data } \# \Rightarrow \pi(\theta | \#_{data}) \Rightarrow \hat{\theta}_B, \hat{f}_T^B, \hat{R}_T^B, \hat{\lambda}_T^B, \dots$$

$$\hat{R}^B(t) = \hat{P}_B(T_{n+1} > t | \#_{data}, \hat{\theta}_B)$$

BAYESovská PREDIKTIVNÍ SPOLEHLIVOST:

$$T|\theta \sim f_T \quad ; \quad \pi \text{ ind } f_T(t|\theta) \quad ; \quad t_{\text{data}}$$

$$\Downarrow \quad f_T^{\text{PR}}(t|t_D) = \int_0^\infty f_T(t|\theta) \cdot \pi(\theta|t_D) d\theta$$

$$R_{T_{m+1}}^{\text{PR}}(t|t_D) = P^{\text{PR}}(T > t | t_D) = \int_t^\infty dt \underbrace{\int f_T \cdot \frac{f_T \cdot \pi(\theta) d\theta}{\int f_T \cdot \pi(\theta) d\theta}}_{f_T^{\text{PR}}(t|t_D)}$$

nebo BAYES $CI_{1-\alpha}^{\text{PR}}(t_L, t_u)$:

$$P^{\text{PR}}(t_L < T_{m+1} < t_u | t_D) = 1 - \alpha$$

Př (Dcv) Testování ventilů - predikce

$T \sim \text{Exp}(\lambda)$ s const. FR $\lambda_T(t) = \lambda$.

Výroba je nestabilní $\Rightarrow \pi(\lambda) = \text{Gamma}(\alpha, \beta)$

$\Downarrow$ $(T_j)_1^m$ iid $\text{Exp}(\lambda) \Rightarrow \pi(\lambda | \mathbf{t}_D) = \text{Gamma}(\alpha + m, \beta + \sum_1^m t_j)$


$$f_T^{\text{PR}}(t | \mathbf{t}_D) = \int_0^\infty \lambda e^{-\lambda t} \frac{(\beta + \sum_1^m t_j)^{m+\alpha}}{\Gamma(m+\alpha)} \cdot \lambda^{m+\alpha-1} e^{-\lambda(\beta + \sum_1^m t_j)} d\lambda =$$

$$= \dots = \frac{(m+\alpha) (\beta + \sum_1^m t_j)^{m+\alpha}}{(t + \beta + \sum_1^m t_j)^{m+\alpha+1}} \sim 1/\text{polyn.}$$

$$R_T^{PR}(t|\#) = \int_t^\infty dt' =$$

$$= \dots = \left(1 + \frac{t}{\beta + \sum_j t_j}\right)^{-n-\alpha}; \quad t > 0$$

"chosest R_T^{PR} " type $\sim 1/t^{n+\alpha}$ při $t \rightarrow \infty$



Př : $X \sim \text{Bin}(n, p)$ POČET PORUCH za čas t .

např. paralelní systém shodných komponent

(serverů, HDD RAID, multiprocessorové PC,

pojistné události aut / domů... ,

nemoc zaměstnance na přepážkách bank,

překročení kapacity uzlů sítě (MEU), ...)

! nepotřebujeme model spolehl. $T_j \sim F_T / R_T / \lambda_T / \dots$

systém nepřístupný $\rightarrow$ občasná kontrola po
čas t ... divadelně

$X(w) = x$ počet poruch v m-tici

Odhad $\hat{p}$ ($\hat{p}_{ML}, \hat{p}_M, \hat{p}_{HIMAX}, \hat{p}_B, \dots$)

Predikce kritické havárie $\{X \geq 5\}$ je:

$$P(X \geq 5) = 1 - \sum_{k=0}^4 \binom{n}{k} \hat{p}^k (1 - \hat{p})^{n-k}$$

$$EX = n\hat{p}, \text{ atd.}$$

BAYES nutný: a) znalost / zkušenost z minulosti

$\pi(\theta)$

b) expert z oboru IT = správce systému

SÚ NEMÁ DATA pro $\{X \geq 5\}$!

$X \sim \text{Bi}(n, p)$; $\pi(p) \sim \text{Beta}(a, b)$
charakter experta / minul.

1) apriorní $\hat{p}_a = E \text{Beta}(a, b) = \frac{a}{a+b}$

2) máme (min.) data $x \Rightarrow \hat{p}_{ML} = \frac{x}{n} = \bar{x}_n$

3, Bayes: $\pi(p|x) \sim \text{Beta}(x+a, n-x+b)$

$$\hat{p}_B = \frac{a+b}{a+b+n} \cdot \hat{p}_a + \frac{n}{a+b+n} \hat{p}_{ML}$$

a) n počet komponent první (info v datech x) TEST

$a, b \rightarrow +\infty$ tak, že $b/a = \text{konst.}$ (je omezená / expert se zlepšuje)
 $\Rightarrow \hat{\pi}_B = \hat{\pi}_a$ **TRAIN**

b) a, b pevné (info experta omezená) **TRAIN**
 $n \rightarrow \infty$ (možnost více info z dat x) **TEST**

$$\Rightarrow \hat{\pi}_B = \hat{\pi}_{ML}$$

V obou případech nutnost kvalitních měřících tech.

Pozn: nevlastní aprior. info, limitní apr. info ($a, b = 0$)
Jeffreysova apr. info, neurčitá inf $U(0, 1)$,
....

Exponenciální model $T \sim \text{Exp}(\lambda); \lambda > 0$

$$T \sim f_T(t) = \lambda e^{-\lambda t} \quad ; t > 0$$

$$R_T(t) = e^{-\lambda t} \quad ; \quad \text{MTTF} = \left(\frac{1}{\lambda}\right) !$$

$$R_T(1/\lambda) = e^{-1} \approx 0,3679$$

cFR: $\lambda_T(t) = \lambda$ konst. cFR IFR a DFR

cFRA: $L_T(t) = \int_0^t \lambda dt' = \lambda \cdot t \Rightarrow L_T/t$ konst.

NBU a NWU: $R(x|t) = \frac{P(T > t+x)}{P(T > t)} = e^{-\lambda x} = R_T(x)$

nezávisí na minulosti

NBUE: $\overset{\curvearrowright}{MLR}(t) = \int_0^\infty R(x|t) dx = \int_0^\infty R_T(x) dx = MTTF$
 i NBUE
 bez paměti, věk výrobku nemá vliv!

odhady $\hat{\gamma}$: $\hat{\gamma}_{ML} = \left(\frac{1}{n} \sum_{j=1}^n \overset{\text{TTT total time in test}}{T_j} \right)^{-1} = \overline{T}_n^{-1} = \frac{1}{T(T_n)} \cdot n$

Bayes: $\pi(\gamma) = \text{gamma}(a, b)$ Conjugated fam.

$$\hat{\gamma}_B \overset{L_2}{=} \frac{n+a}{\sum_{j=1}^n t_j + b}$$

nemí invariantní
na transf.

$$\hat{R}_B(t) \neq R_T(\hat{\gamma}_B) = e^{-\hat{\gamma}_B \cdot t}$$

Př: MIXTURE MODELS

Dva závody - výroba - výrobek - s rozdílnou technologií
(různá kvalita)

1. závod $T_1 \dots R_{T_1} = R_1$ s CFR λ_1
2. závod $T_2 \dots R_2$ s CFR λ_2 } $\lambda_1 \neq \lambda_2$.


Výrobky smíchány před prodejem $\alpha : (1-\alpha)$

Náhodně zakoupíme 1 výrobek $\Rightarrow R_T$, MTF?

$$\begin{aligned} R_T(t) &= \alpha R_1(t) + (1-\alpha) R_2(t) = \quad ; t \in \mathbb{R} \\ &= \alpha e^{-\lambda_1 t} + (1-\alpha) e^{-\lambda_2 t} \end{aligned}$$

$$MTTF = \int_0^{\infty} \tilde{R}_T dt = \frac{\alpha}{\lambda_1} + (1-\alpha)/\lambda_2$$

a ! $\lambda_T(t) = -\tilde{R}_T' / \tilde{R}_T = \frac{\alpha \lambda_1 \bar{e}^{-\lambda_1 t} + (1-\alpha) \lambda_2 \bar{e}^{-\lambda_2 t}}{\alpha \bar{e}^{-\lambda_1 t} + (1-\alpha) \bar{e}^{-\lambda_2 t}}$




$$\lim_{t \rightarrow \infty} \lambda_T(t) = \min(\lambda_1, \lambda_2)$$

Zobecnění: $R_T = \sum_j \alpha_j \cdot R_j \Rightarrow \lambda_T = \frac{\sum_j \alpha_j \cdot \lambda_j \cdot e^{-\lambda_j t}}{\sum_j \alpha_j \cdot e^{-\lambda_j t}}$

Př: PHASE-TYPE DISTRIBUTION

State transition diagram



C kritická porucha
D degradační fáze / mód
CD degrad. kritická porucha

$T_c \dots \lambda_c$; $T_d \dots \lambda_d$; $T_{dc} \dots \lambda_{dc}$ nezávisle

$$T_s = \min \{ T_c, T_d + T_{dc} \}$$

$$R_s(t) = P(\min\{T_c, T_d + T_{dc}\} > t) = P(T_c > t, T_d + T_{dc} > t)$$

$$\stackrel{\text{id}}{=} P(T_c > t) \cdot P(T_d + T_{dc} > t) = \text{ /dos. + konvoluce /}$$

$$= e^{-\lambda_c t} \cdot \frac{1}{\lambda_{dc} - \lambda_d} (\lambda_{dc} e^{-\lambda_d t} - \lambda_d e^{-\lambda_{dc} t})$$

⇓

$$\lambda_s(t) = -R_s' / R_s = \lambda_c + \frac{\lambda_d \lambda_{dc} (e^{-\lambda_d t} - e^{-\lambda_{dc} t})}{\lambda_{dc} e^{-\lambda_d t} - \lambda_d e^{-\lambda_{dc} t}}$$

$$MTTF_s = \int_0^{\infty} R_s(t) dt = \frac{\lambda_c + \lambda_d + \lambda_{dc}}{(\lambda_c + \lambda_d)(\lambda_c + \lambda_{dc})}$$

SMIRNOVova TRASFORMace :

$$T \sim R_T. \text{ Def. } \tilde{T} = \Lambda_T(T) = -\ln(1 - F_T(T)).$$

Pak $\tilde{T} \sim \text{Exp}(1) \wedge \lambda_{\tilde{T}}(t) = 1$ (cFR systém).

$$\text{Navíc } T = t \Leftrightarrow \tilde{T} = \Lambda_T(t), \forall t \geq 0.$$

Tzn. původní systém stárnoucí/mládnoucí s poruchou
v čase t_0 je ekvival. se systémem $\tilde{T}$ nestárnoucím
s poruchou v čase $\Lambda_T(t_0) \triangleq$ EXPOncenciální REZERVA
systému T do mom. t .

$$Dk: P(F_T(T) \leq t) = P(T \leq F_T^{\leftarrow}(t)) = F_T(F_T^{\leftarrow}(t)) = t \in (0,1)$$

$$\Downarrow R_T(t) = P(\tilde{T} > t) = P(-\ln(1 - \underbrace{F_T(T)}_{U \sim U(0,1)}) > t) = \\ = P(U > 1 - e^{-t}) = 1 - F_U(1 - e^{-t}) = e^{-t}, \quad t \geq 0$$

Pokud $\lambda_T > 0 \Rightarrow \Lambda_T(t) = \int_0^t \lambda_T(t') dt'$ ostře roste

Aedy $T = t_0$ jednoznačně určuje $\Lambda_T(t_0)$ ^{+ spojitě}

Pozn: Λ_T v praxi neznáme!

bud' máme fyzik. zákon nebo ho lze
odhadnout z dat

PARETO MODEL

Par(k, β)

$$T \sim R_T(t) = \frac{\beta^k}{(\beta+t)^k} = \left(1 + \frac{t}{\beta}\right)^{-k}; \quad \begin{array}{l} \beta > 0, \\ k > 0, \\ t > 0. \end{array}$$

$$\Downarrow f_T(t) = -R_T' = \frac{k\beta^k}{(\beta+t)^{k+1}} = \frac{k}{\beta} \left(1 + \frac{t}{\beta}\right)^{-k}$$

$$\Downarrow \lambda_T(t) = f_T/R_T = \frac{k}{\beta+t}$$

$$MTTF_T = \int_0^{\infty} R_T = \frac{\beta}{k-1}$$

Obr. + MEU

DFR monotonic

$$\lim_{t \rightarrow \infty} \lambda_T = 0$$

! pouze pro $k > 1$ ($\exists$)

Př! Výrobek... $T \sim \text{Exp}(\lambda)$; CFR $\lambda_T = \lambda$. [T/λ]
Nestabilní výroba $\Rightarrow \lambda \sim \text{gamma}(k, \beta)$ [π(λ)]

Bayes $\Downarrow$

$$R_T(t) = \int_t^{+\infty} \int_0^{+\infty} f_{T/\lambda} \cdot \pi(\lambda) d\lambda du^t =$$

$$= \int_0^{\infty} \pi(\lambda) \cdot R_{T/\lambda} d\lambda = \int_0^{\infty} e^{-\lambda t} \frac{\beta^k}{\Gamma(k)} \lambda^{k-1} e^{-\beta \lambda} d\lambda =$$

$$= \frac{\beta^k}{\Gamma(k)} \int_0^{\infty} \lambda^{k-1} e^{-\lambda(t+\beta)} d\lambda = \frac{\beta^k}{(t+\beta)^k} \quad \text{[PARETO]}$$

Nestabilní výroba $\Rightarrow R_T$ polynomiálně klesá!
(= Bayes)

NORMAL MODEL $\sim TS$


$$T \sim R_T(t) = 1 - \Phi\left(\frac{t - \mu}{\sigma}\right) ; t \in \mathbb{R}!$$

$$\lambda_T(t) = -R_T'/R_T = \frac{1}{\sigma} \varphi\left(\frac{t - \mu}{\sigma}\right) / \left(1 - \Phi\left(\frac{t - \mu}{\sigma}\right)\right) =$$

$$= \frac{1}{\sigma} \lambda_{\Phi}\left(\frac{t - \mu}{\sigma}\right), \text{ kde } \lambda_{\Phi} \text{ odpov. } N(0, 1).$$

$$\lim_{t \rightarrow \infty} \lambda_{\Phi}(t)/t = 1$$

$$MTTF = \mu, DT = \sigma^2.$$



Užití: doba opotřebení pneumatik / Pr. (tabule)

Výhoda: $T_S = \sum_{j=1}^L T_j$, T_j iid $\mathcal{L}_2$ s lib. rozdělením.

Pak dle CLT: $T_S \sim AN$ nebo REPRODUKCE.

TN: USEKNUTÉ (truncated) N zleva w $t=0$:

$$R_T^{TR}(t) = P(T > t | T > 0) = \frac{1 - \Phi\left(\frac{t - \mu}{\sigma}\right)}{1 - \Phi\left(\mu/\sigma\right)}; t \geq 0.$$

$$\lambda_T^{TR}(t) = -R_T' / R_T = \frac{1}{\sigma} \lambda_{\Phi}\left(\frac{t - \mu}{\sigma}\right) \quad \text{! pro } t \geq 0 \text{ !}$$

Odhady $\hat{\mu}$, $\hat{\sigma}^2$ standard nebo $\propto TN(\mu, \sigma^2)$!

Gamma MODEL ~ TS

$$T \sim R_T(t) = \int_t^\infty \underbrace{\frac{\lambda}{\Gamma(k)} (\lambda t')^{k-1} e^{-\lambda t'}}_{\text{gamma}(k, \lambda)} dt' ; \quad \begin{array}{l} \lambda > 0, \\ k \in \mathbb{N}(\mathbb{R}), \\ t > 0. \end{array}$$

$$ET = \text{MTTF} = k/\lambda$$

$$DT = k/\lambda^2$$

$$\lambda_T(t) = \frac{t^{k-1} e^{-\lambda t}}{\int_t^\infty t'^{k-1} e^{-\lambda t'} dt'}$$

Obt.

$$\lim_{t \rightarrow \infty} \lambda_T(t) = \lambda !$$

$$\lim_{t \rightarrow 0_+} \lambda_T(t) = \begin{cases} \infty & 0 < k < 1, \\ 0 & k > 1, \\ \lambda & k = 1. \end{cases}$$


$k=1$ Exp(λ) ; $k \in \mathbb{N}$ ERLANGOVO rozdělení

$\lambda \dots$ intenzita šoku ; $\lambda > 0$. [HPP]

$k \dots$ míra rezistence proti šokům ; $k > 0$.

$$k \in \mathbb{N} \Rightarrow \lambda_T(t) = \frac{\lambda (\lambda t)^{k-1} e^{-\lambda t} / \Gamma(k)}{\sum_{l=0}^{k-1} (\lambda t)^l e^{-\lambda t} / l!} \quad [\text{Polynom}^{-1}]$$

Reprodukce : $T_j \sim \text{Gamma}(k_j, \lambda) \Rightarrow$
 $T_S = \sum_j T_j \sim \text{Gamma}(\sum_j k_j, \lambda)$

Užití :  opravy
(plán opt. oprav)

Odhady $\hat{\lambda}, \hat{k}$: MM, MLE, ... [+MEU]

LogGamma MODEL

$$T \sim LG(k, \lambda) \Leftrightarrow U = -\log T \sim G(k, \lambda)$$

Pozor: $T = e^{-U} \in (0, 1)$! TRANSFORMace

Alt: $T \sim G(k, \lambda) \Rightarrow Y = e^{-T} \sim LG(k, \lambda)$
 $Y \in (0, 1)$

(MEU)

$$f_Y(y) = \frac{\lambda^k}{\Gamma(k)} \cdot (-\ln y)^{k-1} \cdot y^{\lambda-1}$$

$$"MTTF_Y" = \left(\frac{\lambda}{\lambda + 1} \right)^k ; \text{DY existuje...}$$

Invert. gamma MODEL

$$T \sim IG(k, \lambda) \Leftrightarrow 1/T \sim G(k, \lambda); \begin{matrix} \lambda > 0 \\ k > 0 \end{matrix}$$

$$f_T(t) = \frac{\lambda^k}{\Gamma(k)} t^{-k-1} e^{-\lambda/t} \quad ; \underline{t > 0}$$

Pozor: $ET = MTTF = \frac{\lambda}{k-1}$ if $k > 1!$
($\exists$)

$$DT = \frac{\lambda^2}{(k-1)^2(k-2)} \quad \text{if } k > 2!$$

MEU!

!! WEIBULL MODEL ~ TS

VK © 2023 KM

$$T \sim \text{Weib}(\alpha, \lambda, \xi) ; R_T(t) = e^{-(\lambda[t-\xi])^\alpha}$$

λ - scale (měřítko)

$$\alpha, \lambda > 0, \xi \in \mathbb{R}, t > \xi.$$

α - shape (tvor)

ξ - location ("poloha")

GARANČNÍ PRAH

$$f_T(t) = \alpha \lambda^\alpha (t - \xi)^{\alpha-1} e^{-(\lambda[t-\xi])^\alpha}, \quad t > \xi.$$

$$R_T(1/\lambda) = P(T > 1/\lambda) = 1/e \doteq 0,3679 \quad \forall \alpha, \xi = 0!$$

$t = 1/\lambda$ mázev CHARAKTERIST. doba života

$$t_{med} = \xi + \frac{1}{\lambda} (\ln 2)^{1/2} \quad \underline{\text{MEDIAŇOVÁ doba života}}$$

$$MTTF_T = \xi + \frac{1}{\lambda} \Gamma\left(1 + \frac{1}{2}\right) \quad \left[\frac{1}{\lambda} = MTTF_{exp.}\right]$$

$$DT = \frac{1}{\lambda^2} \left[\Gamma\left(1 + \frac{2}{2}\right) - \Gamma^2\left(1 + \frac{1}{2}\right) \right]$$

$$\xi = 0 \Rightarrow CV = \frac{\sqrt{DT}}{MTTF} \quad \underline{\text{nezávisí na } \lambda!}$$

Použití: nejpoužívanější rozdělení, velmi flexibilní:
 Waloddi Weibull (švéd 1887-1979) - TEXTIL. vlákna
 převodovky, ložiska kulíčková, motory,
 bodové svary, biologické organismy, pacienti, ...
LIFETIME DATA (medicína - klinické testy)

Pr: Škrtici ventily: DATA $(t_1, \dots, t_m) \dots$ Weib

Adhady: $\hat{\alpha} = 2,25$; $\hat{\lambda} = 1,15 \cdot 10^{-4} h^{-1}$; $(\xi = 0)$

$$R_T(6 \text{ měsíců}) = R_T(4380 h) = \underline{0,808}$$

$$MTTF = \Gamma(1,44) / 1,15 \cdot 10^{-4} h = 7706 h \approx \underline{321 \text{ dne}}$$

$$t_{med} = 7389 h$$

$$\begin{aligned} R_T(1 \text{ rok} | 6 \text{ měsíců}) &= R_T(8760 / 4380) = \\ &= R_T(8760) / R_T(4380) = \underline{0,448} \end{aligned}$$

$$MRL(4380) = \frac{1}{R_T(4380)} \int_0^{\infty} R_T(4380 + x) dx = \overset{197 \text{ dne}}{\underline{4730 h}} \text{ (aprox. výř.)}$$

ODHADY α, λ, ξ : [předp. $\xi = 0$]

MM : $\sqrt{DT}/MTTF \doteq \sqrt{\Delta_M^2}/\bar{T}_M \Rightarrow$ odhad $\hat{\alpha}_M$ *iterace!*
 $\Rightarrow \hat{\lambda}_M \doteq \Gamma(1 + \frac{1}{\hat{\alpha}_M})/\bar{T}_M$, resp. $\frac{(\ln 2)^{1/\hat{\alpha}_M}}{\bar{T}_{med}}$!

ML : $\partial_{\alpha} = 0, \partial_{\lambda} = 0$ pro $\log L(\alpha, \lambda)$

$\Rightarrow \hat{\lambda}_{ML} = \left(\frac{n}{\sum_{j=1}^n t_j^{\hat{\alpha}_{ML}}} \right)^{1/\hat{\alpha}_{ML}}$, kde

$\hat{\alpha}_{ML}$ je řešením r. $\frac{n}{\alpha} + \sum_{j=1}^n \ln t_j - n \frac{\sum_{j=1}^n t_j^{\alpha} \ln t_j}{\sum_{j=1}^n t_j^{\alpha}} = 0$

[$\hat{\xi}_{ML}$ num. iterace]

NUMERICKY!

QE (KVANTILOVE ODHADY) :

VK © 2023 KM FJFI

soustava : $F_T(\hat{t}_{p_1}; \alpha, \tau) = p_1$, kde $\hat{t}_{p_1}, \hat{t}_{p_2}$
 $F_T(\hat{t}_{p_2}; \alpha, \tau) = p_2$ jsou výběrové
kvantily!

řešení :
$$\hat{\alpha}_Q = \frac{\ln(-\ln(1 - \frac{p_1}{n})) - \ln(-\ln(1 - \frac{p_2}{n}))}{\ln t_{(1)} - \ln t_{(n)}} \quad [\hat{t}_p = t_{([n \cdot p] + 1)}]$$

$$\hat{\tau}_Q = \left[-\ln\left(1 - \frac{p_1}{n}\right) \right]^{1/\hat{\alpha}_Q} / t_{(n)}$$

Optimalizace (z pohledu asympt. eficiency odhadů(MC))
 $\hat{\alpha}_Q: p_1 = \frac{2}{n} = 0,1673, p_2 = \frac{7}{n} = 0,9737 \mid \hat{\tau}_Q: 0,3978; 0,8211 \mid$

Bayes : $\hat{\alpha}_B$; $\hat{\gamma}_B$?

Weib. nemá postačující stat. dim $< n$

tedy nemá Conjugated family (CF)
(jednodušší)

Nutná numerika (Gibbs, Metropolis, ...)

pro získání $\pi(\alpha, \gamma | t)$, ksp. pro

$E^\pi[\alpha, \gamma | t_{\text{data}}]$ při L_2 !

INTENZITA PORUCH [FR] :

$$\lambda_T(t) = f_T / R_T = \alpha \lambda^\alpha (t - \xi)^{\alpha-1} \quad ; \quad t > \xi$$

$$\left[\begin{array}{l} \alpha > 1 \Rightarrow \text{IFR } \forall \lambda \\ \alpha = 1 \Rightarrow \text{CFR } \lambda_T = \lambda \quad [\text{Exp}(\lambda)] \\ \alpha < 1 \Rightarrow \text{DFR } \forall \lambda \end{array} \right.$$

$$(\alpha = 2 \Rightarrow \lambda_T(t) = 2\lambda(t - \xi) \quad [\text{Linear}])$$

RAYLEIGHovo rozdělení

IFR

Obr. [využití v MEU $\alpha > 1$ těžší ohrost]

! V: [REPRODUKCE MINIMA]

$$T_S = \min(T_j)_1^m!$$

seriový systém komp.
nezávislé m. rel. / komp.

$$(T_j)_1^m \sim \text{Weib}(\alpha, \lambda_j), \forall j \in \hat{m}$$

$\Downarrow$

$$R_S(t) = P(T_S > t) = P(\min_{\hat{m}} T_j > t) \stackrel{\text{id. / nezav. /}}{=} \prod_{j=1}^m P(T_j > t) = \prod_{j=1}^m R_{T_j}(t) = \prod_{j=1}^m e^{-(\lambda_j t)^\alpha} =$$

$$= \exp\left\{-\left(\sum_{j=1}^m \lambda_j^\alpha\right) \cdot t^\alpha\right\} \stackrel{\text{ozn.}}{=} \exp\left\{-(\lambda_S t)^\alpha\right\} \sim \text{Weib}(\alpha, \lambda_S)$$

$$\text{kde } \lambda_S = \left(\sum_{j=1}^m \lambda_j^\alpha\right)^{1/\alpha} = \| \lambda \|_\alpha$$

special: $\lambda_j = \lambda, \forall j \Rightarrow \lambda_S = \lambda \cdot m^{1/\alpha};$

$$MTTF_S = \frac{1}{m^{1/\alpha}} \cdot MTTF_1$$

Př.: sada ozub. kol /
řemenů / ložisek
počet m objektů, ...

LogNormal model v TS : $LN(\mu, \sigma^2)$

$$T \sim LN(\mu, \sigma^2) \Leftrightarrow \ln T \sim N(\mu, \sigma^2)$$

$$R_T(t) = P(\ln T > \ln t) = 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right)$$


$$f_T(t) = \frac{1}{\sqrt{2\pi}\sigma} \cdot \frac{1}{t} \exp\left\{-\frac{1}{2\sigma^2}(\ln t - \mu)^2\right\}; \underline{t \geq 0}$$

(! MEU - těžší pr. CHVOST!)

$$t_{med} = e^{\mu}; \quad t_{mode} = e^{\mu - \sigma^2} = t_{med} \cdot e^{-\sigma^2}$$

$$\underline{MTTF} = e^{\mu + \frac{\sigma^2}{2}} = t_{med} \cdot e^{\frac{\sigma^2}{2}}$$

($t_{mode} < t_{med} < MTTF$)




FR: $\lambda_T(t) = f_T / R_T = \varphi\left(\frac{\ln t - \mu}{\sigma}\right) \cdot \frac{1}{\sigma t} / 1 - \Phi\left(\frac{\ln t - \mu}{\sigma}\right)$

$\lim_{t \rightarrow \infty} \lambda_T(t) = 0 !$

Tvar : ?

Použití : ?



! Repair time distribution

ROZDĚLENÍ DOBY do OPRAVY !

zpočátku intenzita opravy roste, avšak pokud oprava trvá delší čas, pak to indikuje vážný problém (nedostatek náhr. dílů) a tedy intenzita opravy pak od t_0 klesá !

Další zajímavé vlastnosti $\mathcal{LN}$:

a) $(T_j)_1^m \sim \mathcal{LN}(\mu_j, \sigma_j^2)$ nezávislé $\Rightarrow$

$$T_S = \prod_1^m T_j \sim \mathcal{LN}\left(\sum_1^m \mu_j, \sum_1^m \sigma_j^2\right)$$

b) $(T_j)_1^m$ iid $\mathcal{L}_2$ $\wedge$ $ET_j = \mu$ a $DT_j = \sigma^2 < \infty$.

Pak pro GEOMETRICKÝ PRŮMĚR $G_m = \left(\prod_1^m T_j\right)^{1/m}$

platí $G_m \sim \mathcal{ALN}(\mu, \sigma^2)$, $\ln G_m \sim \mathcal{AN}(\mu, \frac{\sigma^2}{m})$,

neboli $(G_m / e^\mu)^{\sqrt{m}} \xrightarrow{\mathcal{D}} \mathcal{LN}(0, \sigma^2)$

Dk: $\ln(G_m / e^\mu)^{\sqrt{m}} = \sqrt{m} (\ln G_m - \mu) = \sqrt{m} (\bar{T}_m - \mu) \xrightarrow{\mathcal{D}} \mathcal{N}(0, \sigma^2)$

Δ -metoda pro spoj. dif. $q(\mu) = e^\mu$: $(G_m / e^\mu)^{\sqrt{m}} \xrightarrow{\mathcal{D}} e^{\mathcal{N}(0, \sigma^2)} = \mathcal{LN}$.

ODHADY (μ, σ^2) : a MM OK: $MTTF = e^{\mu} \cdot e^{\frac{\sigma^2}{2}} = \bar{T}_m$

$$DT = e^{2\mu} (e^{2\sigma^2} - e^{\sigma^2}) = \Delta_m^2$$

! vlastnosti prozkoumány v MAS cv.

Pozn: zjednodušen: $t_{med} = e^{\mu} = \hat{T}_{1/2} \Rightarrow \hat{\mu}_Q \uparrow$

b Quantilové odhady: OK fajn: $\hat{\sigma}^2 = 2 \ln(\bar{T}_m - \ln \hat{T}_{1/2})$

$$\hat{\mu}_Q = \frac{1}{2} (\ln t_{(r)} + \ln T_{(m-r)})$$

$$\hat{\sigma}_Q = \frac{1}{2\mu_{r/m}} (\ln t_{(r)} - \ln T_{(m-r)}) ;$$

$\mu_{r/m}$ je $\frac{r}{m}$ kvantile
 $N(0, 1)$

optim. $r/m \doteq 0,07$ pro $\hat{\sigma}_Q$ a opt. $r/m \doteq 0,27$ pro $\hat{\mu}_Q$.

Pr: Interval spolehlivosti + ERROR FACTOR

$$P(t_L < T < t_U) = P\left(\underbrace{\frac{\ln t_L - \mu}{\sigma}}_{\mu_\alpha} < \underbrace{\frac{\ln T - \mu}{\sigma}}_{N(0,1)} < \underbrace{\frac{\ln t_U - \mu}{\sigma}}_{\mu_{1-\alpha}}\right) = \frac{1-2\alpha}{}$$

$$\Downarrow$$
$$t_{U,L} = e^{\mu \pm \sigma \mu_{1-\alpha}} = t_{\text{med}} \cdot e^{\pm \sigma \mu_{1-\alpha}} = \begin{cases} t_{\text{med}} \cdot k \\ t_{\text{med}} / k \end{cases}$$

$k = e^{\sigma \mu_{1-\alpha}}$ se nazývá (1-2α) error faktor !

Pr: data... praxe... odhad $\hat{t}_{\text{med}}$ a $\hat{k}_{1-2\alpha}$ dostupné
 $\Rightarrow \hat{\mu} = \ln \hat{t}_{\text{med}}$ a $\hat{\sigma} = \ln \hat{k}_{1-2\alpha} / \mu_{1-\alpha}$! **ROBUST**

Pozn: Procesy OBNOVY / HROM. OBSLUHY



$T \sim$ doba do poruchy / života $\lambda_T(t)$

$O \sim$ doba opravy $\lambda_O(t)$

Repairable systems: T_j id $\text{Exp}(\lambda)$; O_j id σ_{ϵ_j} HPP

Komplikace: T_j id $\text{Weib}(\alpha, \lambda)$ resp. Gamma, LN ;
 O_j id $LN(\mu, \sigma^2)$

$$\Rightarrow R_{TS} = R_{\sum T_j + \sum O_j} = R_{\sum T_j} * R_{\sum O_j} \quad ?? \underline{AS.}$$


Unarové zkoušky / Fatigue analysis

Δ ... cyklický stres / amplituda zatížení

$\vec{F}_\Delta$... periodická síla $\vec{F}_\Delta = \Delta \cdot \sin(\varphi t)$

N_Δ ... počet cyklů do rozlomení / poruchy

$T_\Delta \leftrightarrow N_\Delta$, protože $T_\Delta = N_\Delta \cdot \Delta t$, kde



Je model $LN(\mu, \sigma^2)$ pro $T \leftrightarrow N$ vhodný?

a) tvar OK, ale $\lim_{t \rightarrow \infty} \lambda_T(t) = 0$

často užívaný, ale ne vždy ideálně sedí!

b) Wöhlerův S-N diagram

Fyzika materiálů: $N \cdot S^b = c$, kde

b, c konstanty charakterizující

geometrii mater., vlastnosti materiálu,
ošetření povrchu, provozní prostředí,


$$\log \underline{N} = \log c - b \log \underline{s} \quad \left(+ \varepsilon \sim N\left(\overset{\sum \varepsilon_i \cdot CLT}{\underset{2||}{0}}, \sigma^2\right) \right)$$

$$\Rightarrow \log N \sim N(\mu, \sigma^2), \quad \text{txn } N \Leftrightarrow T \sim \text{LN}$$

BĚŽNÁ GAUSSOVSKÁ REGRESE !


založená na datech $(N_j, s_j)_1^k \rightarrow$

$\rightarrow$ odhad $\hat{c}, \hat{b} \rightarrow$ PREDIKCE $\hat{N}$ pro nové $\underline{s}$



WÖHLER diag. - Srovnání materiálů.
(životnost)

$\ln s_0 \dots$ únavový limit!
(ocel $s_0 > 0$ vs. ocel korozí)



WOHLERův diagram ($S-N$)

! BIRNBAUM-SAUNDERS model v TS

na míru cyklickým únavovým testům (1969)

Z_i - částečné poškození (růst trhlinky)
při i -tém cyklu se zatížením $\underline{\Delta}$

$$i \in \hat{m}; (Z_i)_1^m \text{ iid } \mathcal{L}_2 \quad E Z_i = \mu, D Z_i = \sigma^2, \forall i$$

(rozdělení Z_i $\mathcal{L}_2$ závisí na typu stresoru a na vlastnostech materiálu)

$W_m = \sum_1^m Z_i$... celkové poškození po m cyklech
 w ... ozn. kritickou hranici poškození $\rightarrow$ zlom

$$\begin{aligned}
 P(N \leq n) &\sim P(W_n > w) = 1 - P\left(\sum_1^n z_i \leq w\right) = \\
 &= 1 - P\left(\underbrace{\frac{\sum_1^n z_i - n\mu}{\sqrt{n}\sigma}}_{\text{dle CLT je } AN(0,1)} \leq \frac{w - n\mu}{\sqrt{n}\sigma}\right) \approx 1 - \Phi\left(\frac{w - n\mu}{\sigma\sqrt{n}}\right)
 \end{aligned}$$

dle CLT je $AN(0,1) \Rightarrow$

$\Downarrow$ přeznačím $N \rightarrow T$; $n \rightarrow t$ (viz $T \sim N \cdot \Delta t$)

$$P(T \leq t) = F_T(t) = 1 - \Phi\left(\frac{w - t\mu}{\sigma\sqrt{t}}\right) = \dots$$

$\Downarrow$

$$R_T(t) = \Phi\left(\frac{1}{\alpha}\left(\frac{1}{\sqrt{\lambda t}} - \sqrt{\lambda t}\right)\right), \quad t > 0.$$

$\phi(-x) = 1 - \phi(x)$

$\lambda = \mu/w$
 $\alpha = \sigma/\sqrt{\mu \cdot w}$

$T \sim R_T$ je $BS(\lambda, \alpha)$
 (resp. zob. $BS(\lambda, \alpha, \xi)$)

$\alpha > 0$ shape par.
 $\lambda > 0$ scale par.

$$MTTF_T = \int_0^{\infty} R_T = \frac{1}{\lambda} \left(1 + \frac{\alpha^2}{2}\right)$$

$$DT = \frac{\alpha^2}{\lambda^2} \left(1 + \frac{5\alpha^2}{4}\right)$$

} MM možná
 $\hat{\lambda}_M, \hat{\lambda}_M$
 (resp. MLE)
 Až OK


$$U = \frac{1}{2} \left(\sqrt{\lambda T} - \frac{1}{\sqrt{\lambda T}} \right) \sim N(0, 1)$$

$$\Downarrow f_T(t) = \frac{1}{2\alpha t} \left(\sqrt{\lambda t} + \frac{1}{\sqrt{\lambda t}} \right) \varphi \left(\frac{1}{\alpha} \left(\sqrt{\lambda t} - \frac{1}{\sqrt{\lambda t}} \right) \right); t > 0$$

$$\lambda_T(t) = f_T / R_T = \dots \quad \lim_{t \rightarrow \infty} \lambda_T(t) = \lambda / 2\alpha^2 !$$

Mírně těžší pravý chvost než Gauss ($f_T \sim \frac{1}{\sqrt{t^3}} e^{-c \cdot t}$)
Použití: Fatigue; modely REDUNDANTNÍCH systémů.

$$BS(\lambda, \alpha): \lambda_T(t):$$



Př: Stroj v posilovně $\left\{ \begin{array}{l} n_1 \text{ cyklů se zatížením } \lambda_1 \\ \text{KONVOLUCE } BS(\lambda_j, \alpha_j) \\ j \in \hat{K} \end{array} \right\} n_k \text{ cyklů se zatížením } \lambda_k$

Inverzní GAUSSOVO model v TS

[Schrödinger (1915)]

$$T \sim \text{IG}(\mu, \lambda) \quad \text{if}$$

$$t > 0$$

$$f_T(t) = \sqrt{\frac{\lambda}{2\pi t^3}} e^{-\frac{\lambda}{2\mu^2}(t-\mu)^2/t} ; \mu, \lambda > 0$$

μ není lokální parametr
 λ není scale parametr

TVAR $\lambda_T(t)$: "jako" LN typové, ale

$$\lim_{t \rightarrow \infty} \lambda_T(t) = \frac{\lambda}{2\mu^2} \neq 0 \quad ! \text{Fatigue OK}$$

Odkady $(\mu, \lambda) : \underline{MM} : \begin{aligned} MTTF_T &= \mu \\ DT &= (\mu^3 / \lambda) \end{aligned}$

MLE: $L(\mu, \lambda) \quad \partial_{\mu} = 0 \quad ; \quad \partial_{\lambda} = 0$

$\Rightarrow \hat{\mu}_{ML} = \bar{t}_m \quad ; \quad \hat{\lambda}_{ML}^{-1} = \frac{1}{m} \sum_{j=1}^m \left(\frac{1}{t_j} - \frac{1}{\bar{t}_m} \right).$

LOGISTIC distr. $Lo(\mu, \Delta)$

$$R_T(t) = \frac{1}{1 + e^{\frac{t-\mu}{\Delta}}} \quad ; \quad t \in \mathbb{R} !$$

$(\mu \in \mathbb{R}, \Delta > 0)$

$$f_T(t) = \frac{1}{\Delta} \frac{e^{-\frac{t-\mu}{\Delta}}}{(1 + e^{-\frac{t-\mu}{\Delta}})^2}$$

ala' Gauss, ale
 Δ "těžšími chvosty."

!! Pro TS_{pol.}: LOG-LOGISTIC model:

$$T \sim LL(\alpha, \beta) \Leftrightarrow \log T \sim Lo(\mu, \Delta),$$

kde reparametrizujeme $\mu = \ln \alpha, \Delta = 1/\beta$.

$$R_T(t) = \frac{\alpha^\beta}{\alpha^\beta + t^\beta} \quad ; \quad t > 0! \quad [\text{typ PARETO}]$$


! Polynomiálně těžký chvost! [MEU]

$t_{\text{med}} = \alpha$; $ET < \infty$ pro $\beta > 1$!
 typově podobné LN pro $\beta > 1$, ale

$$\lambda_T(t) = \frac{\beta}{\alpha} \frac{(t/\alpha)^{\beta-1}}{1 + (t/\alpha)^\beta} :$$

$\beta \leq 1 \Rightarrow \text{DFR}$

$\beta > 1 \Rightarrow \text{Unimodal}$
 (IFR & DFR)



GOMPERTZ distrib. model v TS

$$R_T(t) = e^{-\gamma(e^{bt} - 1)}$$

$$MTTF_T = \frac{1}{b} e^{\gamma} \int \frac{e^{-u}}{u} du$$

; $t \geq 0, b, \gamma > 0$
(b scale, γ shape)

$$\lambda_T(t) = \gamma b e^{bt}$$

EXPONENCIÁLNÍ RŮST

intenzity poruch!

stále hůř a hůř!

Použití: demografie, gerontologie,
aktuární vědy, biologie, hydrologie,
spolehlivost ~~of~~ SW kódů, life-time, ...
data

GOMPERTZ-MAKEHAM model (law of mortality)

$$R_T(t) = e^{-\lambda t - \frac{\alpha}{\beta}(e^{\beta t} - 1)}$$

$$t > 0; \\ \alpha, \beta, \lambda \in \mathbb{R}^+ \\ (\lambda = 0 \text{ lxe})$$

$$\lambda_T(t) = \lambda + \alpha e^{\beta t}$$

pro $\lambda = 0$ přechází na GOMPERTZ dist.
s $b = \beta$ a $\gamma = \alpha/\beta$!

NEPARAMETRICKÉ ODH./METODY

Využití: (a) odhady $\hat{R}_m, \hat{\gamma}_m(t)$ *nezávislé na rodině F !*

(b) detekce parametrické rodiny !!

díky souladu param. $R_{\hat{\theta}}$ s nepar. $\hat{R}_m$.

(c) GoF tests a testy homogeneity: $H_0: R_1 = R_2$.

(d) plug-in odhady skrze STATISTICKÝ

FUNKCIONAL $\theta = \theta(R_T) \Rightarrow \hat{\theta}_m = \theta(\hat{R}_m)$.

($\hat{R}_m$ značí "empirickou" spolehlivostní fci) [ERF]

$T \sim F \dots t = (t_1, \dots, t_m) \dots t_{(i)} = (t_{(1)}, \dots, t_{(m)})$
USPOŘÁDANÝ VÝBĚR

Přímé neparam. odhady: $\bar{t}_m, \hat{t}_\alpha, \hat{t}_{\text{medián}},$
 $\hat{s}_m^2, \hat{\sigma}_m^2, \hat{m}_r$ odhady $EX^r, \dots$

$\hat{CV}_m = \hat{s}_m / \bar{t}_m$ výběrový koeficient variace

$T \sim \text{Exp}(\lambda) \Rightarrow CV_T = 1, \forall \lambda > 0$

Užití: pokud $\hat{CV}_m$ daleko od 1, pak
se nejedná o Exp rozdělení!

$$F_n[EDF] \Rightarrow \boxed{R_n(t)} = 1 - F_n(t) = \frac{\#\{T_j > t\}}{n} [ERF]$$

!! $F_n \xrightarrow{R} F$ s.j. (Glivenko - Cantelli)

$\forall t$ měřenný, konzistentní, $AN(F(t), \frac{F(t)(1-F(t))}{n})$

$\downarrow$
 $R_n(t)$ je $\forall t$ měřenný, konzist., stýnoměrně konzist. $R(t)$

a $R_n(t) \sim AN(R(t), \frac{1}{n} R(t)(1-R(t)))$, $\forall t$.

(Dk: protože $nR_n(t) \sim Bi(n, p = R(t))$, viz def. $R_n(t)$)

Užití: $(1-\alpha) \cdot 100\%$ asýpt. konfidenční int. pro $R(t)$, $\forall t$,

ze vztahu $\sqrt{n}(R_n(t) - R(t)) \xrightarrow[\text{aprox.}]{\text{"2"}} N(0, R(t)(1-R(t)))$
 ($\mu_{1-\alpha/2} = 1,96$)


CROWDERŮV PLOT (Crowder et al. 1991):

VK © 2023 KM

$$\{t_{(j)}, \bar{R}_m(t_{(j)})\}_{j=0}^m$$

kde $t_{(0)}=0$, $\bar{R}_m(t_{(0)})=1$,

$$\begin{aligned} \bar{R}_m(t_{(j)}) &= \frac{1}{2} [R_m(t_{(j)}) + R_m(t_{(j)}^-)] \\ &= 1 - \frac{j - \frac{1}{2}}{m}, \quad \forall j \in \hat{m}. \end{aligned}$$



(nemí bona-fide odhadem)

VIZUÁLNĚ HLADŠÍ +

bodová nebo pospojovaná (spojitá) verze!


VK © KM 2023 FJF

WEIBULL PROBABILITY PLOT [WPP]

$$\downarrow T \sim \text{Weib}(\lambda, \alpha) \Rightarrow R_T(t) = e^{-(\lambda t)^\alpha}, t > 0,$$

$$\ln[-\ln R_T(t)] = \alpha \ln \lambda + \alpha \underline{\ln t}, t > 0.$$


$$\text{\# data} \Rightarrow WPP = \{ \ln t_{(j)}, \ln[-\ln \bar{R}_m(t_{(j)})] \}_{j=1}^n.$$



regrese: odhad $\hat{\alpha}$ a $\hat{\lambda}$
 $\hat{\alpha}_{WPP} \sim$ směrnice přímky
 $\hat{\lambda}_{WPP} \sim e^{\text{intersept} / \hat{\alpha}_{WPP}}$

Pokud WPP aprox. přímka $\Rightarrow$
 $\Rightarrow$ R_T lze modelovat Weib!

NEPARAMETRICKÝ ODHAD FR $\lambda_T(t)$:



n ... počet objektů / časů do poruchy.

m_i ... počet poruch v intervalu I_i . (zde $m_i = 2$)

t_{ji} ... časy strávené v testu, $\forall j \in \hat{m}$.

(j -té komponenty uvnitř I_i)

$$t_{1i} = \dots = t_{7i} = \underline{0}$$


$$t_{8i}, t_{9i} \neq 0; \quad t_{10i} = \underline{\Delta t_i}$$

$m_i \dots$

$$\hat{\lambda}_{T,m}(t) = \frac{m_i}{\sum_{j=1}^m t_{ji}}, \quad \forall t \in I_i.$$

TTT TRANSFORMACE d.f. F

$$T \sim F \quad \text{def. } H_F^{-1}(v) = \int_0^{F^{-1}(v)} \frac{F^{-1}(v)}{(1-F(t))} dt, \quad \begin{aligned} & (F^{-1}(0) \text{ def} = 0) \\ & v \in [0, 1] \\ & (F^{-1}(1) = t_F) \end{aligned}$$



$H_F^{-1} \leftrightarrow F$
Barlow & Campo '75

Spec. $H_F^{-1}(1) = \int_0^{F^{-1}(1)} R(t) dt = ET = \mu = MTTF, \text{ if } \exists \frac{1}{\mu} > 0.$

Def: $\varphi_F(v) = H_F^{-1}(v) / H_F^{-1}(1) = \frac{1}{\mu} H_F^{-1}(v), \quad v \in [0, 1].$

$\Psi_F(v)$: SCALED (Škálovaná) TTT transformace
(normováno: $\Psi_F \in [0, 1]$)


Př: $T \sim \text{Exp}(\lambda) \Rightarrow F(t) = 1 - e^{-\lambda t} \Rightarrow$

$\Rightarrow F^{-1}(v) = -\frac{1}{\lambda} \ln(1-v), v \in [0, 1]$

$$H_F^{-1}(v) = \int_{F^{-1}(0)}^{F^{-1}(v)} e^{-\lambda t} dt = \left[-\frac{1}{\lambda} e^{-\lambda t} \right]_0^{-\frac{1}{\lambda} \ln(1-v)} =$$

$$= \frac{1}{\lambda} (1 - (1-v)) = v/\lambda$$

scaled $\Psi_F(v) = v/\lambda / \underbrace{ET}_{1/\lambda} = v$



Př: $T \sim \text{Weib}(\overset{\text{shape}}{\alpha}, \underset{\text{scale}}{\lambda}) \Rightarrow F(t) = 1 - e^{-(\lambda t)^\alpha}; \alpha > 0, \lambda > 0$

$\Rightarrow F^{-1}(v) = \frac{1}{\lambda} (-\ln(1-v))^{1/\alpha}, v \in [0, 1].$

$H_F^{-1}(v) = \int_0^{\overset{F^{-1}(v)}{\leftarrow}} e^{-(\lambda t)^\alpha} dt = \left| \frac{u = (\lambda t)^\alpha}{du = \dots} \right| = \frac{1}{\lambda \alpha} \int_0^{-\ln(1-v)} u^{\frac{1}{\alpha}-1} e^{-u} du$

(neúplná Γ fce ... aprox. numerika)

$ET = H_F^{-1}(1) = \frac{1}{\lambda} \Gamma(1 + \frac{1}{\alpha})$

scaled $\varphi_F(v) = \frac{1}{\alpha \Gamma(1 + 1/\alpha)} \int_0^{-\ln(1-v)} u^{1/\alpha-1} e^{-u} du$ NEZÁVISÍ
ma !

Obv $\alpha < 1$ KONVEXNÍ, $\alpha > 1$ KONKÁVNÍ, $\alpha = 1$ CONST. (EXP)

Pro Weib(α, λ) máme, že $\alpha < 1 \Rightarrow \text{DFR}$ ($\alpha = 1$ CFR)
 $\alpha > 1 \Rightarrow \text{IFR}$

? Je zde souvislost H_F^{-1} Konvex/konkáv. $\leftrightarrow$ DFR/IFR?
 (resp. bathubové)

V: Necht' F spojitá a ostře rostoucí na oboru
 $F^{-1}(0) \stackrel{\text{def.}}{=} 0 < t < F^{-1}(1)$.

Pak $H_F^{-1}(F(t)) = \lambda_T^{-1}(t)$, $\forall t$ z oboru $\hookrightarrow$ (Dk:)

Důsl: F je IFR/DFR $\Leftrightarrow H_F^{-1}$ konkáv./konvex. na $[0, 1]$

Dk: F IFR $\Leftrightarrow \lambda_T$ neklesá $\Leftrightarrow \lambda_T^{-1}$ neroste $\Leftrightarrow$

$\Leftrightarrow H_F^{-1}(F(t))$ neroste $\Leftrightarrow H_F^{-1}(v)$ neroste ($v = F(t)$ rostoucí)

$\Leftrightarrow H_F^{-1}(v)$ konkávní! (DFR obdobně)

EMPIRICKÁ TTT transformace

JK©2023 KM
FJFI čvut

plug-in F_m EDF za F do H_F^{-1} a Ψ_F :

(def.) $H_m^{-1}(v) = \int_0^{F_m^{-1}(v)} R_m(t) dt$, $v \in [0, 1]$,
 $F_m^{-1}(0) \triangleq 0$,
 $F_m^{-1}(1) = t_{(m)}$.
 (pro $\Pi(\text{ind})F$ a t data)

VLASTNOSTI: $F_m(v) \xrightarrow[t \rightarrow v]{\leftarrow^{-1}} F(v)$ až na spočetně mnoho
 výjimek

$$R_m \xrightarrow{R} R_{sj} \left[F_m \xrightarrow{R} F_{sj} \text{ STK G.-C.L.} \right]$$

Pak $H_{F_m}^{-1} = H_m^{-1}(v) = \int_0^{F_m^{-1}(v)} R_m(t) dt \xrightarrow[t \rightarrow v]{\leftarrow^{-1}} \int_0^{F^{-1}(v)} R(t) dt = H_F^{-1}(v)$.

$\text{např.: } H_m^{-1}(1) = \int_0^{F_m^{-1}(1)} R_m(t) dt = \int_0^{t_m} (1 - F_m(t)) dt =$
 $\text{spec.: } = \frac{1}{n} \sum_{j=1}^n t_{(j)} = \bar{t}_m \sim \bar{T}_m \xrightarrow{\text{s.j.}} H_F^{-1}(1) = \mu. \quad \text{MTTF}$

Def: empirickou scaled / škálovanou TTT transf.

$\varphi_m(r) = H_m^{-1}(r) / H_m^{-1}(1) = \frac{1}{\bar{t}_m} \int_0^{\bar{F}_m^{-1}(r)} (1 - F_m(t)) dt.$


Plyne, že $\varphi_m(r) \xrightarrow{\text{s.j.}} \varphi_F(r)$, $\forall r \in [0, 1]$,

! CITLIVOST OK v těle F ,
 nižší citlivost ve CHVOSTECH neb $\left\{ \begin{array}{l} \varphi_F(0) = 0, \varphi_m(0) = 0, \\ \varphi_F(1) = 1, \varphi_m(1) = 1. \end{array} \right.$ **FIXED ↑**

TTT PLOT: je množ. bodů/graf:

$$\left\{ \frac{i}{m}, \varphi_m\left(\frac{i}{m}\right) \right\}_{1 \leq i \leq m} = \left\{ \frac{i}{m}, \frac{H_m^{-1}\left(\frac{i}{m}\right)}{H_m^{-1}(1)} \right\}_{1 \leq i \leq m} \quad \left(\text{linear. interpolation} \right)$$

Výpočet: $H_m^{-1}\left(\frac{i}{m}\right) = \int_0^{F_m^{-1}\left(\frac{i}{m}\right)} (1 - F_m(t)) dt = \int_0^{t(i)} R_m(t) dt =$



$$= \sum_{j=1}^i \frac{1}{m} t_{(j)} + (m-i) \cdot \frac{1}{m} t_{(i)} =$$

$$= \frac{1}{m} \left[\sum_{j=1}^i t_{(j)} + (m-i) t_{(i)} \right] \approx \underline{\underline{H_F^{-1}\left(\frac{i}{m}\right)}}$$

$\left(\frac{1}{m}\right) \sum_{j=1}^i t_{(j)}$ plocha $\checkmark$ ozn: $\sum_{j=1}^i t_{(j)}$ - total time in test $\checkmark$ $t_{(i)}$

Tedy TTT plot = $\left\{ \frac{i}{n}, \frac{T(t_{(i)})}{T(t_{(n)})} \right\}_1^n \approx \left\{ \frac{i}{n}, \varphi_F\left(\frac{i}{n}\right) \right\}$

aprox. $\uparrow$
skutečná

! Využítí: a) TTT plot $\sim$ konkáv/konvex. aprox. ?


b, volba param. rodiny (Weib(α, λ))

c, odhady param. $\hat{\Theta}(\hat{\alpha}, \hat{\lambda}) \rightarrow \hat{F}$

d) $H_{\hat{F}}^{-1}(v)$ pro $\hat{F}$ (Weib($\hat{\alpha}, \hat{\lambda}$))

e) vykreslíme TTT plot(x dat)

a přes něj vykreslíme $H_{\hat{F}}^{-1}(v)$ pro
odhadnutý param. model $\hat{F}$ (Weib)



aprox. SHODA či NESHODA ?

**KONVEX. vs. KONKÁV.
vs. LINEAR (ExpA)**


PREVENTIVNÍ ÚDRŽBA

VK© 2023 KM
FJFI ČVUT

A) Age replacement policy

1) PREVENTIVNÍ VÝMĚNA součásti po čase ^{age} $t_0 > 0$,
náklady na prevent. výměnu ozn. (c) .

2) VÝMĚNA PŘI PORUŠĚ součásti v neplán. čase
náklady + extra výdaje na "opravu" ozn. $(c+k)$.
(ztráta produkce jaderné elektrárny,
HW, lidé, klínový řemen + ventily, ...)



Smysluplná prevence, pokud $k > 0$ a pokud
je intenzita poruch $\lambda_T(t)$ současně rostoucí!

Celkové náklady v čase t jsou $\sum_{\text{plán}} c + \sum_{\text{porucha}} (c+k)$ (?)

Tedy $t_0 > 0$ fixed age

↓ Označ. $T \sim F$ doba do poruchy součásti (ASR)
Střední náklady na výměnnou periodu jsou $c + k \cdot P(T \leq t_0)$.

Pak STŘEDNÍ NÁKLADY za jednotku času výměn. periody

jsou $C_A(t_0) = \frac{c + k \cdot F(t_0)}{MTBR(t_0)}$, kde

$MTBR(t_0)$ značí Mean Time Between Replacements /
Renewals (s obnovovacím stářím t_0).

Výpočet MTBR(t_0):

ozn. Z ... náhod. veličinu "DOBA DO VÝMĚNY"

$$Z(T) = \begin{cases} T & \text{pokud } T < t_0, \\ t_0 & \text{pokud } T \geq t_0. \end{cases}$$

$$\text{Pak } \underline{\text{MTBR}(t_0)} = E[Z(T)] = \int_0^{\infty} z(t) f(t) dt =$$

$$= \int_0^{t_0} t f(t) dt + \int_{t_0}^{\infty} t_0 f(t) dt =$$

$$= \int_0^{t_0} t f(t) dt + t_0 \cdot (1 - F(t_0)) = \left| \left[t(1 - F(t)) \right]_0^{t_0} \right|_{+ \text{ per partes}}$$

$$= \int_0^{t_0} (1 - F(t)) dt = \left| \frac{F(t_0) = N_0}{t_0 = F^{-1}(N_0)} \right| = H_F^{-1}(N_0) \underline{\underline{TTT_{transf}}}$$

$$\begin{aligned} \text{Tedy } C_A(t_0) &= \frac{c + k \cdot F(t_0)}{MTBR(t_0)} = \frac{c + k F(t_0)}{\int_0^{t_0} (1 - F(t)) dt} = \\ &= \left| \begin{array}{l} F(t_0) = n_0 \\ t_0 = F^{-1}(n_0) \end{array} \right| = \frac{c + k \cdot n_0}{H_F^{-1}(n_0)} = \frac{c + k \cdot n_0}{(\mu \cdot \varphi_F(n_0))} \stackrel{\text{ozn.}}{=} C_A(n_0) \end{aligned}$$

ÚKOL: optimalizace obnovenacího stáří (age) t_0 !

$$a, n_{0, \min} = \underset{n_0}{\operatorname{argmin}} \frac{c + k \cdot n_0}{\varphi_F(n_0)}$$

$$b, t_{0, \min} = F^{-1}(n_{0, \min}) \text{ je optimální } t_0^{\text{opt}}$$

F nemáme $\Rightarrow \varphi_F$ ani F^{-1} nemáme!

Řešení: odhady z dat $(T_j)_{j=1}^m \Rightarrow \varphi_m$ a F_m empirická!

nebo parametrický
odhad F

Nalezení $n_{0, \min}$ diferenciálním počtem:

$$\Downarrow \frac{d}{dn_0} \left[\frac{c + k \cdot n_0}{\varphi_F(n_0)} \right] = \frac{k \cdot \varphi_F(n_0) - \varphi_F'(n_0)(c + k \cdot n_0)}{\varphi_F^2(n_0)} = 0$$
$$\varphi_F'(n_0) = \frac{\varphi_F(n_0)}{c/k + n_0}, \text{ resp. } \frac{\varphi_F'}{\varphi_F} = (\log \varphi_F)'_{n_0} = \frac{1}{c/k + n_0}$$


diferenc. rovnice pro $n_0 \dots$ řešení $n_{0, \min}$.

Grafická reprezentace + grafické řešení:

$$\varphi_F(n_0) = \varphi_F'(n_0) (n_0 - (-c/k))$$

je rovnice tečny k funkci $\varphi_F(n)$ v bodě n_0
procházející bodem $(-c/k)$ na ose n !

if $n_0^{opt} = 1 \Rightarrow$
 $\Rightarrow t_0^{opt} = F^{-1}(1) = t_F$
 $\Rightarrow$ NO PREVENTIVE
 REPLACEMENT
 needed



φ_F konkávní
 (předp. IFR)

- METODA:
- 1) Empirická TTT transform. $\varphi_n \rightarrow$ **PLOT**
 - 2) Detekce param. rodiny F_Θ (např. Weib $(\alpha, 1)$)
 - 3) Odhad parametrů $\hat{\Theta}_n$ $(\hat{\alpha}, \hat{\lambda})$
 - 4) Vykreslení φ_F + bod $(-c/k)$ na ose n
 - 5) Tecna $k \varphi_F \Rightarrow n_0^{opt} \Rightarrow t_0^{opt} = \hat{F}^{-1}(n_0^{opt})$.

Def: $C_A(\infty) = \lim_{t_0 \rightarrow \infty} C_A(t_0) = \lim_{t_0 \rightarrow \infty} \frac{c + k \cdot F(t_0)}{\underbrace{H_F^{-1}(N_0)}_{\int_0^{t_0} R(t) dt}} =$
 $= \frac{c + k}{H_F^{-1}(1)} = \frac{c + k}{\underbrace{\text{MTTF}}_{\mu}} \quad (\text{if } ET < \infty)$

$C_A(\infty)$ reprezentuje žádnou preventivní strategii (jen poruchy)

Def. $(\ell_{t_0})^{-1} = \frac{C_A(t_0)}{C_A(\infty)} = \frac{c + k \cdot F(t_0)}{H_F^{-1}(N_0)} \cdot \frac{\mu}{c + k} =$
 $= \frac{1 + \kappa \cdot F(t_0)}{1 + \kappa} \cdot \varphi_F^{-1}(N_0) \quad , \text{ kde } \kappa = \frac{k}{c}.$


ℓ_{t_0} nazýváme nákladovou efektivitou příslušné (k/c) preventivní údržby s obnovovacím věkem t_0 .

P_T: $T \sim \text{Weib}(\alpha, \lambda)$; $\alpha > 1$ IFR.

$$P_{ak} (e_{t_0})^{-1} = \frac{1 + \kappa(1 - e^{-(\lambda t_0)^\alpha})}{1 + \kappa} \cdot \frac{\frac{1}{\lambda} \Gamma(1 + \frac{1}{\alpha})}{\int_0^{t_0} (e^{-(\lambda t)^\alpha}) dt} =$$

$$= \left/ \begin{array}{l} \text{subst.} \\ \lambda t_0 = \mu_0 \\ \lambda t = \mu \end{array} \right/ = \frac{1 + \kappa(1 - e^{-\mu_0^\alpha})}{1 + \kappa} \cdot \frac{\Gamma(1 + \frac{1}{\alpha})}{\int_0^{\mu_0} e^{-\mu^\alpha} d\mu}$$


nexávisimá
jen skóre μ_0 :
($t_0 = \mu_0 / \lambda$)



only failure replacements
(no preventive policy)

preventive area
(μ_0, t_0 optim.)
 $\mu_{0,min} \Rightarrow t_{0,min}$
 $t_{0,opt}$

B) BLOCK replacement policy:



Výhoda: snazší administrace (velký počet součástek)

Nevýhoda: výměna i potenciálně téměř nové součástky

Smysluplné, pokud $c < k$, resp. $c \ll k$.

$$C_B(t_0) = \frac{1}{t_0} (c + k \cdot F(t_0)) \Rightarrow t_0^{\text{opt}} = t_{0,\min}$$

$$\Rightarrow \text{řešíme: } C'_B(t_0) \approx \underline{c + kF(t_0) - k \cdot t_0 \cdot F'(t_0) = 0} \quad \begin{array}{l} ? \text{ grafic.} \\ \text{reprezentace} \end{array}$$

Př: $T \sim \text{Weib}(\alpha > 1, \lambda)$ dosadíme do rovnice $\nwarrow$:

$$\frac{c}{k} + 1 - e^{-(\lambda t_0)^\alpha} = t_0^\alpha \lambda^\alpha t_0^{\alpha-1} e^{-(\lambda t_0)^\alpha} \quad / (\lambda t_0)^\alpha = \mu_0$$

$$\frac{c}{k} + 1 = (1 + \alpha \mu_0) \cdot e^{-\mu_0} \quad \begin{array}{l} \text{řešíť num.} \\ \text{neboť} \end{array} \quad e^\mu \approx 1 + \mu + \frac{\mu^2}{2}$$

$$\frac{c}{k} + 1 \doteq (1 + \alpha \mu_0) \left(1 - \mu_0 + \frac{\mu_0^2}{2}\right) \quad \left(\begin{array}{l} t_0 \text{ předp. malé} \\ \Rightarrow \mu_0 \text{ též malé} \end{array} \right)$$

$$\mu_{0, \text{aprox}}^{\text{opt}} \doteq \dots$$

Spec. $c/k = 1/2 = 0,1$ a $\alpha = 2 \Rightarrow t_0^{\text{opt}} = \frac{(\mu_0^{\text{opt}})^{1/\alpha}}{\lambda} \doteq 0,35 \cdot \frac{1}{\lambda} =$

$$\alpha = 3 \Rightarrow t_0^{\text{opt}} \doteq 0,44 \cdot \text{MTTF} \quad \quad = 0,39 \cdot \text{MTTF}$$

01 SKE

2h/týden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY

KONEC části-I

©VK 2023 KM FYFI

01 SKE ČÁST II

2h/týden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY !


VÁCLAV KŮS , KM FYFI ČVUT

© VK 2023 (KM FYFI ČVUT)

RBD - reliability block diagrams


Logická spojení komponent (STRUKTURY)

Př: Potrubí se 2ma ventily: real layout



a) UZAVŘENO? Funkční, pokud alespoň 1x ventilu°
uzavřen a řesní!

Paralelní str. →



b) OTEVŘENO? Funkční, pokud obě ventily otevřené ⇒ RBD

Sériová str. ↓



D: n -komponentní systém; $S = \{1, 2, \dots, n\}$
 i - i -tá komponenta;
 x_i - stav i -té komponenty: $x_i = \begin{cases} 1 & \text{funguje;} \\ 0 & \text{NOK.} \end{cases}$

Předpokládáme, že známe-li $x = (x_1, \dots, x_n)$,
pak známe stav (funkčnost) celého systému.

ozn. $\phi(x) = \begin{cases} 1 & \text{systém funguje;} \\ 0 & \text{systém NOK.} \end{cases}$

ϕ se nazývá STRUKTURNÍ FUNKCE
KOMPONENTNÍHO SYSTÉMU (STRUKTURY)

A) SÉRIOVÁ STRUKTURA




$$(x_i)_1^m = \begin{cases} 1 \\ 0 \end{cases}$$

$$\text{Pak } \phi(x) = x_1 \cdot x_2 \cdot \dots \cdot x_m = \prod_{i=1}^m x_i = \min (x_i)_1^m.$$

B) PARALELNÍ STRUKTURA

$$\text{Pak } \phi(x) = 1 - \prod_{i=1}^m (1 - x_i)$$



$$\text{ozn. } = \prod_{i=1}^m x_i = \max (x_i)_1^m$$

(ip produkt "inverzní" produkt)

C) k-out-of-n (k-oo-n) STRUKTURA

System funguje, pokud je funkčních alespoň k z n komponent.

$$\phi(x) = \begin{cases} 1 & \text{if } \sum_{i=1}^n x_i \geq k, \\ 0 & \text{if } \sum_{i=1}^n x_i < k, \end{cases} \quad 1 \leq k \leq n.$$


Spec. n -oo- n je sériová struktura (A))

1 -oo- n je paralelní struktura (B))

2-oo-3 : alespoň 2 detektory požáru ze 3 hlásí poplach

2-oo-4, 3-oo-4 : alespoň 2, resp. 3, pumpy ze 4 upumpují potřebný výkon tlaku média.

Př: 2-00-3 : a) RBD:



representace RBD jako
paralelní systém (sériových) minimálních cest!


$$\phi(x) = x_1 x_2 \cup x_1 x_3 \cup x_2 x_3 = \bigsqcup_{(i,j) \in \{(1,2), (1,3), (2,3)\}} (x_i, x_j) =$$

$$= 1 - (1 - x_1 x_2)(1 - x_1 x_3)(1 - x_2 x_3) =$$

$$= x_1 x_2 + x_1 x_3 + x_2 x_3 - x_1^2 x_2 x_3 - x_1 x_2^2 x_3 - x_1 x_2 x_3^2 + x_1^2 x_2^2 x_3^2 = \underline{\underline{\underline{x_i^2 = x_i}}} = x_1 x_2 + x_1 x_3 + x_2 x_3 - 2x_1 x_2 x_3.$$

2-00-3 : b, RBD:

RBD representation.



jako sériový systém (paralelních) minim. řezů!

$$\begin{aligned}\phi(x) &= \prod_{(1,2)(1,3)(2,3)} (x_i \cup x_j) = [1 - (1-x_1)(1-x_2)] \cdot [\\ &[1 - (1-x_1)(1-x_3)] \cdot [1 - (1-x_2)(1-x_3)] = \\ &= 1 - (1-x_1)(1-x_2) - \dots (1-x_1)^2(1-x_2)^2(1-x_3)^2 = \\ &= \underline{\underline{1 - (1-x_i)^2 = 1 - x_i}} = x_1x_2 + x_1x_3 + x_2x_3 - 2x_1x_2x_3.\end{aligned}$$

D+V: Mějme systém $S = \{1, 2, \dots, n\}$ s n komponentách.

Pak $C \subset S$ nazýváme cesta, pokud C svým fungováním zajišťuje funkčnost celého systému S .

C se naz. MINIMÁLNÍ CESTA, pokud C nelze redukovat bez ztráty statusu cesty!

Pak $\phi_s(x) = \bigsqcup_{j=1}^k \prod_{i \in C_j} x_i$, kde $C_j, j \in \hat{k}$,
je sada všech možných minimálních cest v systému S .

(reprezentace jako paralel. struktura minim. cest)

D+V: Mějme systém $S = \{1, 2, \dots, m\}$.

Pak $R \subset S$ nazveme řezem, pokud nefunkčnost R způsobuje nefunkčnost celého systému S .


R je MINIMÁLNÍ ŘEZ, pokud R nelze redukovat bez ztráty statusu řezu!

Pak $\phi_S(\mathcal{K}) = \bigcap_{j=1}^k \bigcup_{i \in R_j} x_i$, kde $R_j, j \in \hat{k}$,
je sada všech
možných minimálních řezů v syst. S .

(reprezentace jako sériová struktura minim. řezů)

Pr: BRIDGE:

(a) sada min. cest.




$$C_1 = \{1, 4\}; C_2 = \{2, 5\};$$

$$C_3 = \{1, 3, 5\} ; C_4 = \{2, 3, 4\}.$$

$$\phi(x) = \prod_{j=1}^4 \prod_{i \in C_j} x_i = 1 - (1-x_1x_4)(1-x_2x_5)(1-x_7x_3x_5) \cdot (1-x_2x_3x_4)$$

$$= \frac{1}{\underline{\underline{\underline{x_i^2 = x_i}}}} = \dots$$

RBD representation:




② VK 2023 KM F3F1

b) sada minim. řezu :


$$R_1 = \{1, 2\}; R_2 = \{4, 5\};$$

$$R_3 = \{1, 3, 5\}; R_4 = \{2, 3, 4\}$$



$$\phi(x) = \prod_{j=1}^4 \bigwedge_{i \in R_j} x_i = [1 - (1-x_1)(1-x_2)] \cdot [1 + (x_4-1)(1-x_5)] \cdot [1 - (1-x_1)(1-x_3)(1-x_5)] \cdot [1 - (1-x_2)(1-x_3)(1-x_4)]$$

RBD reprezentace :



(Designer
vs.
Saboteur)

V: (PIVOTÁLNÍ DEKOMPOZICE systému)

a, volme $i \in \hat{n}$ v syst. S o n komponentách.

$$\text{Pak } \phi(x) = x_i \cdot \phi(1_i, x) + (1 - x_i) \cdot \phi(0_i, x), \quad \forall x,$$

kde $(1_i, x)$ je vektor x s funkcí i -tou komp.

a $(0_i, x)$ je x s nefunkcí i -tou kompon.

b, Rekurentním rozkladem $\phi(1_i, x)$ a $\phi(0_i, x)$...

$$\text{dostaneme } \phi(x) = \sum_{b \text{ binar}} \left[\prod_{j=1}^n x_j^{b_j} (1-x_j)^{1-b_j} \right] \phi(b)$$

kde suma probíhá přes všechny binární vekt. b dim n !


Př: Bridge pro pivot x_3

$$i = 3 \Rightarrow$$




$$\phi(x) = x_3 \phi(1_3, x) + (1 - x_3) \phi(0_3, x), \text{ kde}$$

$\phi(1_3, x)$ je strukt. fce systému:



a

$\phi(0_3, x)$ je strukt. fce systému:



$$\phi_{S_1} = (x_1 \cup x_2)(x_4 \cup x_5) = (x_1 + x_2 - x_1 x_2)(x_4 + x_5 - x_4 x_5)$$

a

$$\phi_{S_2} = x_1 x_4 \cup x_2 x_5 = x_1 x_4 + x_2 x_5 - x_1 x_2 x_4 x_5$$

KOHERENTNÍ SYSTÉMY


© VK2023 KM FJFI

Def: $S = \{1, 2, \dots, n\}$. Pak i -tá komponenta se nazývá irelevantní, pokud

$$\phi(1_i, x) = \phi(0_i, x), \text{ pro } \forall (\cdot_i, x) = x_{-i}.$$

Komponenta je relevantní, pokud není irelevantní.

Př:



[2] je irelevantní pro funkčnost systému,

ale může být [2] "relevantní" jiným způsobem (záznam, zařízení, hlášení poruchy, ...)

Def: Systém komponent S se nazývá
KOHERENTNÍ, pokud všechny jeho kompo-
nenty jsou relevantní a strukturální fce
 $\phi(x)$ je neklesající v každé své proměnné!
(tedy pokud opravíme nebo vyměníme vadnou kompo-
nentu za funkční, pak systém nefunguje hůře).

V: Pro každý koherentní syst. S platí: $\phi_s(0) = 0$;
 $\phi_s(1) = 1$; a $\prod_{i=1}^m x_i \leq \phi_s(x) \leq \bigvee_{i=1}^m x_i$.
(série) (paralel)

STRUKTURÁLNÍ DŮLEŽITOST komponent

Def: Stavový vektor $(1_i, x)$ se nazývá
KRITICKÝ VEKTOR pro i -tou komponentu

pokud $\phi(1_i, x) = 1$ a souč. $\phi(0_i, x) = 0$,

txn. $\phi(1_i, x) - \phi(0_i, x) = 1$.


Celkový počet různých kritických vektorů
systému S pro i -tou komponentu označme

$$\eta_{\phi}(i) = \sum_{x-i} [\phi(1_i, x) - \phi(0_i, x)] .$$

Def: Číslo $B_\phi(i) = \eta_\phi(i) / 2^{m-1}$ se nazývá

BIRNBAUMOVA MÍRA STRUKTURNÍ
DŮLEŽITOSTI i -té KOMPONENTY!

Jde tedy o relativní porci kritických vektorů
pro i -tou komponentu z celkové počtu 2^{m-1}
všech možných stavových vektorů $(i, \mathbf{x}) = \mathbf{x}_i$.

Př:  $\Rightarrow$ $B_\phi(1) = 3/4$ ($i=1$)
 $B_\phi(2) = 1/4$ ($i=2$)
 $B_\phi(3) = 1/4$ ($i=3$)

SPOLEHLIVOST (R_s) KOMPON. SYSTÉMU

©VK'23 FJFI

čas $t > 0$; T_i ... náhod. veličina ; $T_i \geq 0$,
čas do poruchy i -té komponenty

ozn. $X(t) = (X_1(t), \dots, X_m(t))$ binární stavový
vektor systému S v čase $t > 0$.

Pak spolehlivost i -té komp. v čase t je

$$R_i(t) = P(T_i > t) = P(X_i(t) = 1) = E[X_i(t)].$$

Spolehlivost celého syst. S je v čase t :

$$R_s(t) = \underline{P(T_s > t) = P(\phi(X(t)) = 1) = E[\phi(X(t))]}.$$

A) SÉRIOVÁ STRUKTURA : $(\phi(x) = \prod_1^m x_i)$

$$R_s(t) = E[\phi(X(t))] = E\left[\prod_1^m x_i(t)\right] = \text{ /id...nezavislost/ } \\ \text{ /komponent/} \\ \stackrel{\text{id}}{=} \prod_1^m R_i(t) = \text{ /iid/ } = [R_1(t)]^m.$$

Aedy plati : $\left[\min(R_i(t))_1^m \right]^m \leq R_s \leq \min_{i \in \hat{n}} (R_i(t))$
pro id

Př : $m = 100$ komponent ; $R_i(t) = 0,995$, $\forall i \in \hat{n}$.

Pak $R_s(t) = (0,995)^m = (0,995)^{100} = \underline{0,6058}$

(System relativně peruchej !)

V: Pro sériovou strukturu platí, že

$$\lambda_s(t) = \sum_{i=1}^m \lambda_i(t) \quad \text{v případě id. komponent!}$$

Dk: $\underline{R_s(t)} \stackrel{\text{id}}{=} \prod_1^m R_{i_1}(t) = \prod_1^m e^{-\int_0^t \lambda_{i_1}(t') dt'} =$
 $= e^{-\int_0^t \sum_1^m \lambda_{i_1}(t') dt'} = e^{-\int_0^t \underline{\lambda_s(t')} dt'}, \forall t.$

Navíc tedy $MTTF_s = ET_s = \int_0^\infty R_s(t) dt = \int_0^\infty e^{-\int_0^t \sum \lambda_{i_1}(t') dt'} dt.$

Př: $T_i \sim \text{Exp}(\lambda_i)$, id systém. Pak

$$R_s(t) = e^{-\left(\sum_1^m \lambda_i\right)t}, \text{ protože } \lambda_s(t) = \sum_1^m \lambda_i = \text{konst.}$$


$$\text{a } MTTF = 1/\lambda_s = 1/\sum_1^m \lambda_i!$$

- Př:
1. komp. DFR, např. Weib ($\alpha < 1, \tau$),
 2. komp. CFR, $\text{Exp}(\tau) = \text{Weib}(\alpha = 1, \tau)$,
 3. komp. IFR, např. Weib ($\alpha > 1, \tau$).

Pak $\lambda_s(t) = \sum_1^3 \lambda_i(t)$:

Bathhtub komponentu
 lze modelovat jako
 SÉRII tří (či více)

imaginárních nezávislých (id) komponent!
 (PRAXE, využít)



B) PARALELNÍ STRUKTURA ($\phi(x) = \bigwedge_{i=1}^m x_i$)

$$\begin{aligned}
 R_s(t) &= E[\phi(x(t))] = E\left[\bigwedge_{i=1}^m x_i(t)\right] = \\
 &= E\left[1 - \prod_{i=1}^m (1 - x_i(t))\right] \stackrel{\text{id}}{=} 1 - \prod_{i=1}^m (1 - R_i(t)) = \\
 &\stackrel{\text{id!}}{=} 1 - [1 - R_1(t)]^m \quad \text{za předp. nezávislosti (id)!}
 \end{aligned}$$

Tedy platí:

$$\begin{aligned}
 \underbrace{R_s(t)}_{\text{pro id}} &\stackrel{\text{id}}{=} 1 - \prod_{i=1}^m (1 - R_i(t)) \geq 1 - \min_{i \in \hat{m}} (1 - R_i) = \\
 &\stackrel{!}{=} 1 - (1 - \max_{i \in \hat{m}} R_i) = \max_{i \in \hat{m}} R_i(t).
 \end{aligned}$$

Př: $m=100$; $R_i(t) = 0,01 \quad \forall i$
 Pak $R_s(t) = 1 - (0,99)^{100} = \underline{0,634}$

Pozn: $\lambda_s(t)$ pro paralelní strukturu nelze jednoduše vyjádřit (jako u série), protože:

$$R_s(t) \stackrel{\text{id}}{=} 1 - \prod_{i=1}^m (1 - R_i(t)) = 1 - \prod_{i=1}^m \left(1 - e^{-\int_0^t \lambda_i(t') dt'}\right).$$

Totež pro MTTFs $= \int_0^\infty R_s(t) dt = ?$ jednoduše obecně ne

Důsl: Pokud S je koherentní systém s $\phi_s(X)$ a manie s nezávislými (id) komponentami, pak

$$\prod_{i=1}^m R_i(t) \leq R_s(t) \leq \bigcup_{i=1}^m R_i(t) ; \forall t.$$

Př: (2 x HDD do MIRRORU)

1. HDD (značky U)... $T_1 \sim \text{Exp}(\lambda_1)$, cFR λ_1 .


2. HDD (značky V).... $T_2 \sim \text{Exp}(\lambda_2)$, cFR λ_2 .

1 & 2 PARALELNÍ STRUKTURA (mirror)

$$\begin{aligned} \text{Pak } R_s(t) &= \prod_1^2 R_i(t) = 1 - (1 - e^{-\lambda_1 t})(1 - e^{-\lambda_2 t}) = \\ &= e^{-\lambda_1 t} + e^{-\lambda_2 t} - e^{-(\lambda_1 + \lambda_2)t} \quad ; \quad t > 0. \end{aligned}$$

$$\Downarrow \quad \underline{\text{MTTF}_s} = \int_0^{\infty} R_s(t) dt = \frac{1}{\lambda_1} + \frac{1}{\lambda_2} - \frac{1}{\lambda_1 + \lambda_2}.$$

$$\underline{\lambda_s(t)} = \frac{1}{R_s(t)} \left[\lambda_1 e^{-\lambda_1 t} + \lambda_2 e^{-\lambda_2 t} - (\lambda_1 + \lambda_2) e^{-(\lambda_1 + \lambda_2)t} \right].$$



$$\lambda_1 + \lambda_2 = 1$$

$$(\lambda_1 \neq \lambda_2)$$

od $t_0^{\max}$ klesá
tak, že

$$\lim \lambda_s(t) = \min(\lambda_1, \lambda_2)$$

tzn. λ_s konverguje k se' spolehlivější' komp.

Spec. $\lambda_1 = \lambda_2 = \lambda \Rightarrow R_s = 2e^{-\lambda t} - e^{-2\lambda t}; MTTF_s = \frac{3}{2} \cdot \frac{1}{\lambda};$

$$\lambda_s(t) = \frac{2\lambda e^{-\lambda t} - 2\lambda e^{-2\lambda t}}{2e^{-\lambda t} - e^{-2\lambda t}} = \dots$$



c) SPOLEHLIVOST (r) k-oo-m SYSTÉMU

k-oo-m struktura s $R_i(t) = R(t)$, $\forall i \in \hat{n}$, id!

$$\phi_s(X(t)) = \begin{cases} 1 & \text{if } X_s = \sum_1^m X_i(t) \geq k \\ 0 & \text{if } X_s = \sum_1^m X_i(t) < k \end{cases} \quad (X_s = X_s(t)).$$

$$\begin{aligned} \text{Pak } R_s(t) &= E[\phi_s(X(t))] = 1 \cdot P(X_s(t) \geq k) + 0 = \\ &= \left/ \begin{array}{l} \text{rozdělení } X_s(t): P(X_s = x) = P(\sum_1^m X_i = x) = \\ X_s \sim \text{Bin}(m, R(t)): = \binom{m}{x} R(t)^x (1-R(t))^{m-x} \end{array} \right/ = \\ &= \sum_{x=k}^m \binom{m}{x} R(t)^x (1-R(t))^{m-x} \Rightarrow \text{MTTF}_s, \lambda_s(t), \dots \end{aligned}$$

Př: 2-oo-4 $\Rightarrow$ pro $R_i = 0,97 \forall i$ máme $R_s = 0,99989$

Př: k-oo-m s níid komponentami a cFR λ ($\text{Exp}(1)$)

$$R_i(t) = e^{-\lambda t} \Rightarrow R_s(t) = \sum_{x=k}^m \binom{m}{x} e^{-\lambda t x} (1 - e^{-\lambda t})^{m-x}$$

$$\Rightarrow \boxed{\text{MTTF}_s} = \int_0^{\infty} R_s(t) dt = \sum_k \binom{m}{x} \int_0^{\infty} e^{-\lambda t x} (1 - e^{-\lambda t})^{m-x} dt =$$

$$= \left/ \begin{array}{l} u = e^{-\lambda t} \\ dt = -\frac{1}{\lambda} \frac{1}{u} du \end{array} \right/ = \sum_k \binom{m}{x} \frac{1}{\lambda} \int_0^1 u^{x-1} (1-u)^{m-x} du =$$

$$= \frac{1}{\lambda} \sum_k \binom{m}{x} B(x, m-x+1) = \frac{1}{\lambda} \sum_{x=k}^m \binom{m}{x} \frac{(x-1)!(m-x)!}{m!} =$$


$$\boxed{= \frac{1}{\lambda} \sum_{x=k}^m \frac{1}{x}}$$

Zahrnuje paralel. syst. 1-oo-m
i sériový syst. m-oo-m.

SROVNÁNÍ k-oo-m STRUKTUR :

MTTF_s při ind cFR = λ

k \ m	1	2	3	4	5	6	
1	$1/\lambda$	$\frac{3}{2} \cdot \frac{1}{\lambda}$	$\frac{11}{6} \cdot \frac{1}{\lambda}$	$\frac{25}{12} \cdot \frac{1}{\lambda}$	$\frac{137}{60} \cdot \frac{1}{\lambda}$	→ PARALEL	
2		$1/2\lambda$	$\frac{5}{6} \cdot \frac{1}{\lambda}$	$\frac{13}{12} \cdot \frac{1}{\lambda}$	$\frac{47}{60} \cdot \frac{1}{\lambda}$		
3			$1/3\lambda$	$\frac{4}{12} \cdot \frac{1}{\lambda}$	$\frac{47}{60} \cdot \frac{1}{\lambda}$		
4				$1/4\lambda$	$\frac{9}{20} \cdot \frac{1}{\lambda}$		
5					$1/5\lambda$		



$$\vdots \quad \text{MTTF}_{1-oo-4} > 2 \cdot \text{MTTF}_1$$

$$\text{MTTF}_{2-oo-4} > 1 \cdot \text{MTTF}_1$$

! $\text{MTTF}_{2-oo-3} < \text{MTTF}_1$!!

→ SÉRIE

1-00-1 : $R_s = e^{-\lambda t}$


$MTTF = \frac{1}{\lambda}$

1-00-2 : $R_s = 2e^{-\lambda t} - e^{-2\lambda t}$

$MTTF = \frac{3}{2} \cdot \frac{1}{\lambda}$

2-00-3 : $R_s = 3e^{-2\lambda t} - 2e^{-3\lambda t}$


$MTTF = \frac{5}{6} \cdot \frac{1}{\lambda} < \frac{1}{\lambda}$



tedy $MTTF_{2-00-3}$ je 84% $\frac{MTTF_1}{MTTF_2}$

avšak 2-00-3 má vyšší SPOLEHLIVOST $R_s(t)$ v počátečním intervalu $(0, \frac{\ln 2}{\lambda})$!

VÝPOČTY R_S PRO OBECNÉ STRUKTURY



$$R_s(t) = ?$$

dle RBD reprezentace:
 Nakombinujeme { min. cesty, min. řezy,
 pivotální dekompozice

a) Min. cesty $\Rightarrow R_{S_1}(t) = E\left[\bigcup_{j=1}^k \bigcap_{i \in C_j} X_i(t)\right] \neq \bigcup_{j=1}^k \bigcap_{i \in C_j} E\ldots$

b) Min. řezy $\Rightarrow R_{S_2}(t) = E\left[\bigcap_{j=1}^k \bigcup_{i \in R_j} X_i(t)\right] \neq \bigcap_{j=1}^k \bigcup_{i \in R_j} E\ldots$

Pozor: Cesty C_j , resp. řezy R_j , mohou mít společné komponenty, tzn. nemáme NEZÁVISLOST!

c) Pivot X_i $\Rightarrow \underline{R_{S_3}(t)} = E[\phi(X(t))] = E[X_i \phi(1_i, X(t)) + (1 - X_i) \phi(0_i, X(t))]$
 $\stackrel{id}{\uparrow} R_i \cdot R_{1_i} + (1 - R_i) \cdot R_{0_i}$
id - nezávislé komponenty!

d, Plná DEKOMPOZICE S:

$$\begin{aligned}
 R_s(t) &= E[\phi_s(X)] = E\left[\sum_{\substack{\mathbf{b} \\ \text{binary}}} \left\{ \prod_{j=1}^n x_j^{b_j} (1-x_j)^{1-b_j} \right\} \phi_s(\mathbf{b})\right] = \\
 &= \left|_{\substack{b_j=0,1 \\ \text{only}}} \right| \left|_{\substack{\text{id} \\ \text{(max.)} \\ !}} \right| \sum_{\mathbf{b}} \left\{ \prod_{j=1}^n R_j(t)^{b_j} (1-R_j(t))^{1-b_j} \right\} \underline{\underline{\phi_s(\mathbf{b})}}.
 \end{aligned}$$


Tedy stačí experimentálně otestovat funkčnost systému $\phi_s(\mathbf{b}) = \begin{smallmatrix} 1 \\ 0 \end{smallmatrix}$ pro $\textcircled{2^m}$ možných $\mathbf{b}$ stavů systému komponent a pak jen dosadit známé $R_j, j \in \hat{m}$.

REDUNDANTNÍ SYSTÉMY


© VK 2023
KM FJFI

Př: Máme systém S :  se strukt. f. $\phi(x)$.

A) REDUNDANCE SYSTÉMU



B) REDUND. KOMPONENT



$$\phi_{S_1}(x, y) = \phi(x) \sqcup \phi(y) ; \quad \phi_{S_2}(x, y) = \phi(x \sqcup y) ;$$

? $R_{S_1}(t) \leq R_{S_2}(t)$ nebo naopak ?

V: Necht x a y jsou dva stavové vektory $S = \{1, \dots, m\}$.

ozn. $x \cdot y = (x_1 y_1, \dots, x_m y_m)$ a $x \sqcup y = (x_1 \sqcup y_1, \dots, x_m \sqcup y_m)$.

Pak pro koherentní strukturu ϕ platí:


$$\phi(x \cdot y) \leq \phi(x) \cdot \phi(y),$$

$$\phi(x \sqcup y) \geq \phi(x) \sqcup \phi(y).$$

Důs.: $! R_{S_2}(t) = E[\phi(x \sqcup y)] \geq E[\phi(x) \sqcup \phi(y)] = R_{S_1}(t) !$

Tedy zálohování (redundance) na úrovni systému
je horší než zálohování podsystémů nebo komponent!


Varianta REDUNDANCE: c) spočítat si $B_\phi(i)$, $i \in \hat{m}$,
 tedy Birnbaumovu míru strukturální důležitosti,
 a zálohovat pouze tu nejdůležitější komponentu:



$$B_\phi(1) = 3/4$$

$$B_\phi(2) = B_\phi(3) = 1/4$$

Redundance kompon. 1:
 $\Rightarrow \underline{R_S \leq R_{S_3} (\leq) R_{S_1} \leq R_{S_2}}$



? Lze zálohovat ještě lépe než S_1 , S_2 nebo S_3 ?

ANO: S₄: Azv. PASIVNÍ REDUNDANCE bud' na
systémové úrovni, podsystemové úrovni nebo
optimálně (nejlépe) na komponentní úrovni.


a) Aktivní redundance = zapojení rezervní komp.*
do plného provozu (např. paralelně).

b) Pasivní redundance = rezervní komponenta* (-ty)
jsou v "cold standby" režimu!

c) Částečná redundance = rezerva ve slabém zatížení

[b) i c)] ⇒ PROBLÉM: SWITCHING (přepnutí)!

PASIVNÍ REDUNDANCE + PERFECT SWITCHING



.... Aktivní složka / kompon.

$\{2, \dots, n\}$... Pasivní složky / kompon.

! nezapojené, bez zatížení
a nemohou se porouchat!

Funkčnost : [1] porucha $\rightarrow$ (W) přepne (perfect switch)

$\rightarrow$ aktivována [2] $\rightarrow$ porucha [2] $\rightarrow$ (W) přepne...

Předpoklady : Bez možnosti poruchy ve standby režimu
a bez opravování porouchaných složek!

$T_i, i \in \hat{n}$, ozn. čas do poruchy i -te složky
v její aktivní fázi!

Pak $T_s = \sum_{i=1}^m T_i$ a $R_s(t) = R_1(t) * R_2(t) * \dots * R_m(t)$,
KONVOLUCE distribucí


$$MTTF_s = ET_s = \sum_{i=1}^m MTTF_i \quad \text{a} \quad \lambda_s(t) = f_s(t) / R_s(t).$$

Př: $(T_i)_1^m \text{ iid Exp}(\lambda) \Rightarrow T_s \sim \text{Gamma}(m, \lambda) = \text{Erlangovo r.}$

Výhoda PR & PS: Pokud $(T_i)_1^m \text{ iid } \mathcal{L}_2$ a $MTTF_i = \underline{\mu}$, $DT_i = \underline{\sigma}^2$,

pak dle CLT platí: $R_s(t) \approx 1 - \Phi_{N(0,1)}\left(\frac{t - m\mu}{\sqrt{m} \sigma}\right)$. [CLT_Q]

ČÁSTEČNÁ REDUNDANCE + IMPERFECT SWITCHING



Předpokládáme, že $\textcircled{W}$, $\boxed{1}$ a $\boxed{2}$ operujú NEZÁVISLE, neopravujeme je a $\textcircled{W}$ sa nemôže

porouchať jinak, než tým, že není schopen přepnout a nastartovat komp. č. $\boxed{2}$.

$$T_1 \sim R_1(t) \wedge \text{cFR}(\underline{\lambda}_1),$$

$$W \sim R_W(t) \wedge \text{cFR}(\underline{\lambda}_W),$$

$$T_2^0 \sim R_2^0(t) \wedge \text{cFR}(\underline{\lambda}_0),$$

při částeč. zatížení

$$T_2 \sim R_2(t) \wedge \text{cFR}(\underline{\lambda}_2) \text{ jinak.}$$

Volme čas $t > 0$ a necht S je funkcí v $t > 0$. Pak
bud' A) komp. [1] se neporouchá do času t ... s pr. $R_1(t)$!

nebo B) [1] se porouchá v int. $(\tau, \tau + d\tau]$, kde $\tau < t$!

(W) přepne v čase τ s pravděp. $R_W(\tau)$,

[2°] přičemž [2] dožila funkcí do času τ s pr. $R_2^0(\tau)$!

[2] se neporouchá a funguje po celý čas mezi τ
a t , tzn. v int. $(\tau, t]$, ... s pr. $R_2(t - \tau)$!

$$\begin{aligned} P(T_1 \in (\tau, \tau + d\tau]) &= P(\tau < T_1 \leq \tau + d\tau) = R_1(\tau + d\tau) - R_1(\tau) = \\ &= \underline{f_1(\tau) \cdot d\tau} \end{aligned}$$

Protože dle předpokladu $\textcircled{W}$, $\boxed{1}$ a $\boxed{2}$ operují nezávisle,
'cesta' B se skládá ze čtyř nezávislých jevů

B_1 , B_W , B_{2^0} a B_2 ,

přičemž obě 'cesty' A a B jsou disjunkt ní jevy!

Pak $R_s(t) = P(T_s > t) = P(A) + P(B) =$

$$= R_1(t) + \int_0^t R_W(\tau) \cdot R_2^0(\tau) \cdot R_2(t-\tau) \cdot f_1(\tau) d\tau$$

↳ přintegrováno přes všechny potenciální
časy poruchy τ komponenty $\boxed{1}$.

Předpokládejme, že pravděp. přepnutí $\textcircled{W}$ je konstantní
a rovna $(1-p)$ po celou dobu, tzn. $R_W(\tau) = 1-p, \forall \tau < t$.

$$\text{Pak } R_S(t) = \left/ \begin{matrix} T_1 \sim \text{CFR } \lambda_1, & T_2 \sim \text{CFR } \lambda_0, \\ T_2 \sim \text{CFR } \lambda_2 \end{matrix} \right/ =$$

$$= e^{-\lambda_1 t} + \int_0^t (1-p) \cdot e^{-\lambda_0 \tau} \cdot e^{-\lambda_2(t-\tau)} \cdot \lambda_1 e^{-\lambda_1 \tau} d\tau =$$

$$= e^{-\lambda_1 t} + (1-p) \lambda_1 e^{-(\lambda_2)t} \cdot \underbrace{\int_0^t e^{-(\lambda_0 + \lambda_1 - \lambda_2)\tau} d\tau}_{\frac{1}{\lambda_0 + \lambda_1 - \lambda_2} \cdot e^{-(\lambda_0 + \lambda_1 - \lambda_2)t}}$$

$$(\text{pokud } \lambda_0 + \lambda_1 - \lambda_2 \neq 0)$$

$$R_S(t) = \begin{cases} \bar{e}^{-\lambda_1 t} + \frac{(1-\mu)\lambda_1}{\lambda_0 + \lambda_1 - \lambda_2} (\bar{e}^{-\lambda_2 t} - e^{-(\lambda_0 + \lambda_1)t}), & \text{jinak } \uparrow \neq 0 \\ \bar{e}^{-\lambda_1 t} + (1-\mu)\lambda_1 t \bar{e}^{-\lambda_2 t}, & \text{if } \lambda_0 + \lambda_1 - \lambda_2 = 0. \end{cases}$$

$$MTTF_S = \int_0^{\infty} R_S dt = \frac{1}{\lambda_1} + (1-\mu) \underbrace{\frac{\lambda_1}{\lambda_2(\lambda_1 + \lambda_0)}}_{\frac{1}{\lambda_2} - \frac{\lambda_0}{\lambda_2(\lambda_1 + \lambda_0)}} \quad ; \quad \underline{\underline{\forall \lambda_{1,2,3} > 0}}$$

$\mu=0 \Rightarrow$ částečná redund.
& PERFECT Switch

$\mu=0 \wedge \lambda_0=\lambda_2 \Rightarrow$ aktivní redundance (PARALEL)
" $\lambda_0=0$ " ($\lambda_0 \rightarrow 0_+$) $\Rightarrow$ pasivní záloha + ^($\mu \neq 0$)($\mu=0$) imperfect switch!

Př: PUMPA s cFR $\lambda = 10^{-3} \text{ h}^{-1}$; MTTF = 1000 h !

$$\Rightarrow R_s(t)/_{t=1000\text{h}} = e^{-\lambda \cdot 1000} = e^{-1} \doteq \underline{0,3679}.$$

a) Aktivní redundance = 2 pumpy cFR λ paralelně :

$$\Rightarrow R_s(1000\text{h}) = 2 \cdot e^{-\lambda t} - e^{-2\lambda t} /_{t=1000} = 2 \cdot e^{-1} - e^{-2} \doteq \underline{0,6004}.$$

$$\text{MTTF}_{a_1} = \frac{3}{2} \cdot \frac{1}{\lambda} = \underline{1500 \text{ h}}.$$

b) Pasivní záloha s cFR λ & perfect switching :

$$\text{Erlang}(2, \lambda) \Rightarrow R_s(1000\text{h}) = \frac{(\lambda t)^0}{0!} e^{-\lambda t} + \frac{(\lambda t)^1}{1!} e^{-\lambda t} /_{t=1000} =$$

$$= \frac{2}{e} \doteq \underline{0,7357} = 2 \cdot 0,3679 \text{ a } \text{MTTF}_{b_1} = \underline{2000 \text{ h}}.$$

c) Passivní redundance & imperfect switch :

$\mu = 0,015$ (v 1,5% případů switch nepřepne)

$$\downarrow R_s(1000) = [1 + (1 - 0,015) \lambda t] \cdot e^{-\lambda t} / t = 1000h =$$

$$= (1 + 0,985) \cdot e^{-1} \doteq \underline{0,7302}$$

$$MTTF_s = [1 + (1 - 0,015)] \cdot \frac{1}{\lambda} = \underline{1985h}$$

$$\mu = 0,36 \Rightarrow R_s(1000) = 1,64/e \doteq \underline{0,6033} \text{ (cca a)}$$

$$MTTF_s = (2 - 0,36) \cdot \frac{1}{\lambda} = \underline{1640h}$$

$$(\mu = 1 \Rightarrow R_s = 1/e = 0,3679 ; \mu = 0 \Rightarrow R_s \text{ jako v b,)}$$

d) Část. záloha s CFR a imperfect switch:

$$\lambda = 10^{-3} h^{-1} ; \quad \lambda_0 = 2 \cdot 10^{-4} h^{-1} (< \lambda)$$

$$\mu = 0 \Rightarrow R_s(1000h) = \bar{e}^{-1} + \frac{5000}{1000} (\bar{e}^{-1} - \bar{e}^{-1,2}) = \underline{0,7013}$$

$$\mu = 0,2 \Rightarrow R_s(1000) = \bar{e}^{-1} + 0,8 \cdot 5 (\bar{e}^{-1} - \bar{e}^{-1,2}) = \underline{0,6346}$$

$$! \mu = 0,5 \Rightarrow R_s = 3,5 \bar{e}^{-1} - 2,5 \bar{e}^{-1,2} = \underline{0,5346}$$

Docela závisí na kvalitě přepínače, resp.
na kvalitě pracovníka obsluhy přepínače !


SPOLEHLIVOSTNÍ DŮLEŽITOST KOMPONENT

© VK 2023
KMF1

Birnbaumova strukturaální důležitost komp. i ;

$$B_{\phi}(i) = \frac{1}{2^m - 1} \eta_{\phi}(i) = \frac{1}{2^m - 1} \sum_{x \sim i} [\phi(1_{i, x}) - \phi(0_{i, x})],$$

postihuje pouze pozici i -té komp. ve struktuře S ,
ale nepřibliží ke spolehlivosti $R_i(t)$ komponent!



$$B_{\phi}(1) = 3/4, \text{ ale } R_1(t) = 0,98$$

$$B_{\phi}(2) = 1/4, \text{ ale } R_2(t) = 0,65$$

.....

Chceme detekovat slabá místa (bottle necks) S
a komponenty, které stojí za to vylepšit pro
navýšení spolehlivosti $R_S(t)$, např. pomocí

- a, použít kvalitnější komponenty (součástky)
- b, využít redundance (zálohy) - aktiv., pasiv., částec.
- c, omezení operační a environmentální zátěže komp.
- d, alokace inspekci a opravárenských zdrojů
ve prospěch (spolehl.) důležitých komponenty !

Def: Birnbaumova (1969) (spolehl.) míra důležitosti
(importance measure) i -té kompon. v čase $t > 0$

$$\text{je } I_i^B(t) = \frac{\partial R_S(t)}{\partial (R_i(t))}, \quad \forall i \in \hat{n}.$$


$I_i^B(t)$ má velkou hodnotu, pokud má malá změna spolehlivosti i -té komp. $R_i(t)$ má za následek relativně velkou změnu spolehlivosti celého systému $R_S(t)$.

Slouží i ke sběru dat od nejdůležitějších komponent (velká I_i^B) při testování a experimenty se systémy.

Výpočet : $I_i^B(t) = \partial_{R_i} R_S(t) = \left/ \text{dle pivotální dekomp.} \right/ \left/ \text{podle } i\text{-té komp. (id)} \right/ =$

$$= \partial_{R_i} (R_i(t) \cdot R_{1i}(t) + (1 - R_i(t)) \cdot R_{0i}) = R_{1i}(t) - R_{0i}(t),$$

kde R_{1i} je spolehl. syst. s funkční-tou komp. a
 R_{0i} je spol. syst. s nefunkční-tou komp.



Slabina (drawback) I_i^B

je, že sice závisí na struktuře systému (ϕ) i spol. $R_j, j \neq i$,

ale NEZÁVISÍ na spolehl. $R_i(t)$ komp. i samé.

Interpretace $I_i^B(t)$:

$$I_i^B(t) = R_{1i} - R_{0i} = E[\phi(1_i, X) - \phi(0_i, X)] =$$


/kohérent systém/ = $1 \cdot P(\underbrace{\phi(1_i, X) - \phi(0_i, X) = 1}_{\text{počet takových krit. vektorů}}) + 0$

počet takových krit. vektorů = $\eta_\phi(i)$
 v Birnbaumově struktur. důl. $B_\phi(i)$

⇓ Interpretace $I_i^B(t)$ jako pravděpodobnost, že
 $(1_i, X(t))$ je kritický vektor pro i -tou komponentu.
 (Tato forma def. $I_i^B(t)$ funguje i pro závislé (non-id) Komp.)

Def: Číslo $I_i^{IP}(t) = R_{1i}(t) - R_s(t)$, $\forall i \in \hat{m}$,
nazýváme IMPROVEMENT POTENTIAL vzhledem
k i -té komponentě v čase $t > 0$.

V: $I_i^{IP}(t) = I_i^B(t) (1 - R_i(t)) = P((1_i, X) \text{ krit. \& } T_i \leq t)$



$$I_i^B(t) = R_{1i} - R_{0i} =$$

$$= \frac{R_{1i} - R_s}{1 - R_i} = \frac{I_i^{IP}}{1 - R_i}$$

Pozn: CREDIBLE IP: $I_i^{CIP}(t) = R_{s, \max_i}(t) - R_s(t)$.

EVD

EXTREME VALUE DISTRIBUTIONS/MODELS

A)

Předpokládáme SÉRIOVOU strukturu s n iid R_T komponentami.
Pak máme, že $T_S = \min (T_j)_1^n = T_{(1)}$

$$a) T_S \sim R_S(t) = E\left[\prod_1^n X_j(t)\right] \stackrel{iid}{=} \prod_1^n R_j(t) \stackrel{iid}{=} (R_T(t))^n.$$

a) najdeme odhad $\hat{R}_T$ (param./nparam.) $\Rightarrow \hat{R}_S = \hat{R}_T^n$.

b, nalezneme asymptotické rozdělení pro $(R_T(t))^{n \rightarrow \infty}$
a to i bez znalosti přesného tvaru R_T aproxim. R_S !

Pseudonáhled:

©VK2023 KMFJFI

$T \in \mathbb{R}$ lib. s rozdělením F_T , $(T_j)_1^m$ iid F_T .

$$T_s = \min(T_j)_1^m \Rightarrow R_s(t) = [R_T(t)]^m =$$

$$= [1 - F_T(t)]^m = \left[1 - \frac{m F_T(t)}{m}\right]^m \approx e^{-m F_T(t)}$$

($\Downarrow$) $f_s(t) = -R'_s(t) \approx m f_T(t) e^{-m F_T(t)}$!)

(m fixed, m větší)

Důležitý je levý chvost $F_T(t \rightarrow -\infty)$, kdy m je velké a $F_T(t)$ malé v kombinaci $m F_T(t)$.

Pak pro $F_T(t \rightarrow -\infty)$ "exp. typu" bude " $R_s \approx e^{-e^t}$, $t \ll 0$ ".
(typu)

V: (EVD ^{min} typu I) Necht $(T_j)_1^m$ iid f_T , kde

$$f_T(t) = o(e^{-\beta|t|}) \text{ při } t \rightarrow \pm\infty, \text{ kzn.}$$

chvosty f_T jsou (exponenciálního) nebo superexponenciálního typu, a f_T není uškrtnutá zleva ($f_T = -\infty$)

Pak $T_S = \min(T_j)_1^m$ po vhodném posunutí a přeskálování typu $b_m^{-1}(T_S - a_m)$ [viz MEU] konverguje (při $m \rightarrow \infty$)

v distribuci k náhod. veličině $Y \sim F_Y(t) = 1 - e^{-t}$, $t \in \mathbb{R}$,

Rozdělení $F_Y(t) = 1 - e^{-t}$, $t \in \mathbb{R}$, se nazývá [EVD]

GUMBELOVO (1958) asympt. rozdělení nejmenší hodn. typu I!

Vlastnosti Gumbel (0,1) standard $F_Y(t) = 1 - \bar{e}^{-e^t}$, $t \in \mathbb{R}$:


$$R_Y(t) = \bar{e}^{-e^t}; \quad f_Y(t) = e^t \bar{e}^{-e^t} = e^{t-e^t}, \quad t \in \mathbb{R},$$

$$\lambda_Y(t) = f_Y/R_Y = e^t, \quad t \in \mathbb{R}, \text{ exponenciálně roste!}$$

(taxm. bude stále hůř a hůř) (viz GOMPERTZ)

$$MTTF = EY = -\gamma = -0,5772 \quad (\text{Eulerova Konst.})$$

GUMBEL ^{min} std. I:



těžký levý chvost!

lehký pravý chvost!

Location-scale GUMBEL^{min}:

$$Y \sim F_Y(t) = 1 - \bar{e}^{-e^{(t-\eta)/\alpha}} ; \quad \underline{t \in \mathbb{R}}, \quad \underline{\alpha > 0}, \quad \underline{\eta \in \mathbb{R}}.$$

$$\Downarrow R_Y(t) = \bar{e}^{-e^{(t-\eta)/\alpha}}$$

$$\ln(-\ln R_Y(t)) = -\frac{\eta}{\alpha} + \frac{1}{\alpha} t \quad \text{LINEAR} \Rightarrow$$

$\Rightarrow$ GPP $\{t_i, \ln(-\ln R_Y(t_i))\}_1^m$ linear plot!

Využití GPP k identifikaci Gumbel rodingy
(pomocí ^{ERF} R_n); nebo k odhadu parametrů $\hat{\eta}, \hat{\alpha}$.

$$EY = \eta - \alpha \gamma_1 \quad \text{a} \quad \lambda_Y(t) = \frac{1}{\alpha} e^{(t-\eta)/\alpha}.$$

TRUNCATED - TGumbel $(\beta, \varphi) \sim \underline{\underline{TSpoehl.}}$

Gumbelovo rozdělení uškrtnuté zleva v $t=0$.

$T \sim \text{Gumbel}(\eta, \alpha)$. Pak uškrtneme $T \geq 0 \Rightarrow$

$$\Rightarrow \underline{\underline{R_T^0(t)}} = P(T > t | T \geq 0) = \frac{P(T > t)}{P(T \geq 0)} =$$

$$= \frac{e^{-t/\alpha} \cdot e^{-\eta/\alpha} + e^{-\eta/\alpha}}{e^{-\eta/\alpha} (e^{1/\alpha} - 1)} = \frac{e^{-t/\alpha} (e^{1/\alpha} - 1)}{e^{-\eta/\alpha} (e^{1/\alpha} - 1)} =$$


$$= \underline{\underline{e^{-\beta(e^{\varphi t} - 1)}}}, \quad \underline{\underline{t \geq 0!}}, \quad \beta > 0, \varphi > 0.$$

$$\lambda_T^0(t) = -\frac{d}{dt} \ln R_T^0(t) = \frac{d}{dt} (\beta(e^{\varphi t} - 1)) = \beta \varphi e^{\varphi t}, \quad \underline{\underline{t \geq 0.}}$$

Př: PITTING CORROSION (TGumbel^{mini})

© VK 2023
KM FJFI

Ložiska koroze (mx)



STĚNA OCELOVÉ TRUBKY, PLAŠT NÁDOBY,
TLAKOVÉHO ZÁSOBNÍKU, REAKTORU,...

Oxm. D_j - počáteční hloubka mikrokoroze
předpokl., že D_j iid $F_{D_j} = T \text{Exp}(\eta)$

Defin. T_j - čas, kdy j-té ložisko prokoroziví
povrchem a dosáhne max. hloubky δ .

Pak $T_s = \min(T_j)_1^m$ je čas do PORUCHY (ÚNIKU)
media

Aedy jde o fyzicky paralelní systém ložisek (D_j)

o SÉRIOVÉM logickém "zapojení" vzhledem k T_j .

Předpokládejme, že nedochází ke spojování ložisek

a že $\boxed{T_j = k \cdot (\delta - D_j)}$, kde k je konstantní rychlost
koroz měřená v $\text{mm} \cdot \text{t}^{-1}$.

Hledáme přibližné rozdělení T_S doby do úniku:

$$\begin{aligned} F_{T_j}(t) &= P(T_j \leq t) = P(k(\delta - D_j) \leq t) = \textcolor{red}{/0 \leq t \leq k\delta/} \\ &= P(D_j \geq \delta - \frac{t}{k}) = 1 - F_{D_j}(\delta - \frac{t}{k}) = \textcolor{red}{/D_j \sim \text{Exp}(\gamma) /} \\ &= 1 - \frac{1 - e^{-\gamma(\delta - t/k)}}{(1 - e^{-\gamma\delta})} = \frac{1}{c} (-e^{-\gamma\delta} + e^{-\gamma\delta} \cdot e^{\gamma t/k}) = \textcolor{red}{D_j \leq \delta} \\ &= \frac{1}{c} e^{-\gamma\delta} (e^{\gamma t/k} - 1) = \frac{1}{c} (e^{\gamma t/k} - 1). \end{aligned}$$

$$\left[\text{Pozn: } F_{D_j}(d) = P(D_j \leq d \mid D_j \leq \delta) \right]$$

$\forall t, 0 \leq t \leq k\delta,$
 $\forall j \in \hat{m}.$

Pro dostatečně velké n fixed lze psát:

$$\begin{aligned} R_s(t) &= \text{seriová strukt.} = [R_{T_j}(t)]^n = [1 - F_{T_j}(t)]^n \\ &= \left(1 - \frac{1}{n} n F_{T_j}(t)\right)^n \approx e^{-n F_{T_j}(t)} = \text{dosazení} \\ &= e^{-\frac{n}{c_1} (e^{\eta t/k} - 1)} = \text{ozn. } \frac{n}{c_1} = \beta \text{ } \eta/k = \rho = e^{-\beta(e^{\rho t} - 1)} \end{aligned}$$

Tedy $T_s \sim R_s(t)$ má USEKNUTÉ GUMBELOVO (β, ρ) rozdělení (min).
a $\lambda_s(t)$ - intenzita ÚNIKU exponenc. rychle roste!

B) Předpokládejme PARALELNÍ strukturu
s n iid R_T komponentami.

Pak $T_S = \max(T_j)_1^m = T_{(m)}$ a

$$T_S \sim R_S(t) = E\left[\prod_1^m X_j(t)\right] \stackrel{\text{iid}}{=} 1 - \prod_1^m (1 - R_j(t)) = \\ \stackrel{\text{iid}}{=} 1 - (1 - R_T(t))^m \Rightarrow F_S(t) = (F_T(t))^m.$$

a) odhad $\hat{R}_T$ (param./nonparam.) $\Rightarrow \hat{R}_S$, resp. $\hat{F}_S$.

b) asympt. rozdělení $(1 - R_T(t))^m \rightarrow \infty$ a to i bez
znalosti přesného R_T $\Rightarrow$ aproximace R_S pro fixed m !

Pseudomáhled: $T \in R$ lib. s rozd. F_T , $(T_j)_1^m \text{ iid } F_T$.

$$\begin{aligned} \text{Pak } R_s(t) &= 1 - (1 - R_T)^m = 1 - \left(1 - \frac{m R_T}{m}\right)^m \approx \left| \begin{array}{l} m \text{ fixed} \\ m \text{ velké} \end{array} \right| \\ &\approx 1 - e^{-m R_T} = 1 - e^{-m(1 - F_T)}. \end{aligned}$$

Důležitý je pravý chvost $F_T(t \rightarrow +\infty)$, kdy v exp. $m(1 - F_T)$ je m velké a $(1 - F_T)$ malé.

Pak pro $(1 - F_T(t \rightarrow +\infty))$ "exponenciálního typu" (e^{-t})
dostaneme typově $R_s \approx 1 - e^{-e^{-t}}$, $t \gg 0$.

V: (EVD^{max} typu I) Necht $(T_j)_1^m \text{ iid } f_T$, kde

$f_T(t) = o(e^{-\beta|t|})$ při $t \rightarrow \pm\infty$, $\beta > 0$. Superexon.
chvosty,
a f_T není useknutá zprava! ($t_F = +\infty$)

Pak $T_S = \max(T_j)_1^m$ po vhodném posunu a škálování

$$b_m^{-1}(T_S - a_m) \xrightarrow[n \rightarrow \infty]{\mathcal{D}} Y \sim \underline{\underline{F_Y(t) = e^{-e^{-t}}}}, \underline{\underline{t \in \mathbb{R}}}.$$

Rozdělení se nazývá [EVD] GUMBELOVO
asymptotické rozdělení největší hodnoty typu I!



Vlastnosti Gumbel (0,1): $F_Y(t) = \bar{e}^{-t}, t \in \mathbb{R}$:

$$R_Y(t) = 1 - \bar{e}^{-t}; \quad f_Y(t) = \bar{e}^{-t} - \bar{e}^{-t-1}, \quad t \in \mathbb{R},$$

$$\lambda_Y(t) = f_Y/R_Y = \bar{e}^{-t} \left(\frac{\bar{e}^{-t}}{1 - \bar{e}^{-t}} \right) = \bar{e}^{-t} (e^{\bar{e}^{-t}} - 1)^{-1}, \quad t \in \mathbb{R}.$$

$$\text{MTTF} = +\mu = 0,5472$$

Gumbel:
max



$$\lambda_Y(t) = |\bar{e}^{-t}| = y = \frac{y}{e^y - 1}; \quad t = -\ln y$$

Lehký pr. chvost! [MEU]!

Lehký levý chvost $\Rightarrow$ posunutí $\Rightarrow$ vhodné pro T Spolehliv.

Location-scale GUMBEL^{max} :

$$Y \sim F_Y(t) = e^{-e^{-(t-\eta)/\alpha}} ; \quad \begin{array}{l} t \in \mathbb{R}, \\ \alpha > 0, \eta \in \mathbb{R}. \end{array}$$

$$GPP: \ln(-\ln F_Y(t)) = \frac{\eta}{\alpha} - \frac{t}{\alpha} \quad \text{LINEAR} \Rightarrow$$

$$GPLOT: \{t_i, \ln(-\ln F_Y(t_i))\}_{i=1}^m \quad \text{přibližně lineární pro } F_n \text{ EDF}$$

$$EY = \eta + \alpha \gamma, \quad \lambda_Y(t) = \dots \quad + \text{odhad param. } \hat{\eta}, \hat{\alpha}.$$

Truncated TGumbel(β, φ) v TSpoolehlivosti:

useknuté zleva v $t=0$ (nemí až tak nutné; zleva lehčí).

DALŠÍ TYPY EVD^{min} ?

V: Necht' $(T_j)_1^n$ libovolné iid F_T tak, že pro nějaké $\delta \in \mathbb{R}$ a $\alpha > 0$ platí

$$\lim_{t \rightarrow \delta} \frac{F_T(t)}{(t - \delta)^\alpha} = \lambda^\alpha, \text{ kde } \lambda > 0.$$

$\Rightarrow F_T$ "seknutá" zleva
v bodě $\delta = F_T$.

Pak pro $T_S = \underline{\min}(T_j)_1^n$ (SERIAL strukt.)

platí: $n^{1/\alpha}(T_S - \delta) \xrightarrow{d} Y \sim \text{Weib}(\alpha, \lambda)$.

Pozn: Pro $\delta = 0$ ($T_{\text{Spol.}}$) předpokládáme $\lim_{t \rightarrow 0+} \frac{F_T}{(\lambda t)^\alpha} = 1$.

Dk: volume $y > 0$ fixed. Pak

$$R_{n^{1/\alpha}(T_S - \delta)}(y) = P(n^{1/\alpha}(T_S - \delta) > y) =$$

$$P(T_S > \delta + \frac{y}{n^{1/\alpha}}) = [1 - F_T(\delta + \frac{y}{n^{1/\alpha}})]^n$$

viz serial
str. $R_S = [R_T]^n$

$$= \left[1 - \frac{F_T(\delta + \frac{y}{n^{1/\alpha}})}{(\delta + \frac{y}{n^{1/\alpha}} - \delta)^\alpha} \left(\underbrace{\delta + \frac{y}{n^{1/\alpha}} - \delta}_{y^\alpha/n} \right)^\alpha \right]^n =$$



$$= \left[1 - \frac{1}{n} \left(\underbrace{\frac{F_T(\delta + \frac{y}{n^{1/\alpha}})}{(\delta + \frac{y}{n^{1/\alpha}} - \delta)^\alpha}}_{\rightarrow 1^\alpha} \cdot y^\alpha \right) \right]^n \xrightarrow{n \rightarrow \infty} \underbrace{e^{-(1y)^\alpha}}_{R_{Weib}(\alpha, 1)(y)} = \underline{R_{Weib}}$$

Pr: $T \sim F_T = U(0,1)$ nebo $F_T = U(0,\beta)$, $\beta > 0$.
libov.

Pak $\lim_{t \rightarrow 0+} \frac{F_T(t)}{(\lambda t)^\alpha} = \left| \frac{\lambda=1}{\alpha=1} \right| = \lim_{t \rightarrow 0+} \frac{t}{t} = 1$, a tedy

$nT_S = n \cdot \min(T_j)_1 \xrightarrow{D} \text{Weib}(1,1) = \text{Exp}(1)$,

Axn. $F_{T_S} \doteq F_{\text{Exp}(n)}$:



← Obr. k následujícímu Příkladu:

Př: Máme - seriový systém iid s $T_j \sim F_T = \text{Weib}(\alpha, \lambda)$.

$T_S = \min(T_j)_1^n$. Jaké je asympt. rozdělení T_S ?

$$\begin{aligned} \lim_{t \rightarrow 0_+} \frac{F_T(t)}{(\lambda t)^\alpha} &= \lim_{t \rightarrow 0_+} \frac{1 - e^{-(\lambda t)^\alpha}}{(\lambda t)^\alpha} = / \text{L'Hosp.} / = \\ &= \lim_{t \rightarrow 0_+} \frac{\alpha \lambda (\lambda t)^{\alpha-1} e^{-(\lambda t)^\alpha}}{\alpha \lambda (\lambda t)^{\alpha-1}} = \lim_{t \rightarrow 0_+} e^{-(\lambda t)^\alpha} = \underline{\underline{1}}. \end{aligned}$$

nebo $\lim_{n \rightarrow \infty} \frac{e^n - 1}{n} = 1$

Pak $n^{1/\alpha} T_S \xrightarrow{d} \text{Weib}(\alpha, \lambda)$, tzn. $T_S \approx \text{Weib}(\alpha, n^{1/\alpha} \lambda)$,

což je ale současně přesným rozdělením $T_S = \min(T_j)_1^n$,
protože Weibull má vlastnost reprodukce minima $W(\alpha, \|\lambda\|_\infty)$.
 $(\alpha, \lambda_j) + \text{id}$

V: Necht' $(T_j)_1^m$ lib. iid F_T taková, že pro nějaké $\delta \in \mathbb{R}$ a $\alpha > 0$ platí

$$\lim_{t \rightarrow \delta} \frac{1 - F_T(t)}{(\delta - t)^\alpha} = \lim_{t \rightarrow \delta} \frac{R_T(t)}{(\delta - t)^\alpha} = \lambda^\alpha, \quad \underline{\lambda > 0}.$$

Pak pro $T_S = \underline{\max(T_j)_1^m}$ (parallel str.) platí, že
 $n^{1/\alpha}(\delta - T_S) \xrightarrow{d} Y \sim \text{Weib}(\alpha, 1).$

Význam: a) F_T musí být "useknutá" xprava v bodě $\delta = t_F$.
 b) $T_S = \max(T_j)_1^m$ má asympt. NEGATIVE WEIBULL rozdělení
po posunutí $(-\delta)$ a přeskálování $1/n^{1/\alpha}$.

01 SKE 2h/týden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY

KONEC části - **II**

©VK 2023 KM FYFI

01 SKE ČÁST-III

2h/týden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY !

VÁCLAV KŮS , KM FYFI ČVUT

© VK 2023 (KM FYFI ČVUT)

!! CENZOROVANÁ DATA !!

©/K 2023
KM FJFI

Type I - CENSOROVÁNÍ ČASEM (t_c)

Experiment ukončen po dosažení času $t_c > 0$!

Struktura dat: $T_{(1)}, T_{(2)}, \dots, T_{(n)}$, kde

n je náhodnou veličinou ($n \in \{0, 1, \dots, m\}$),

& informace, že zbývajících $(m-n)$ poruch $T_{(n+1)} > t_c$,
 $\dots, T_{(m)} > t_c$ překročilo čas konce experimentu $t_{\text{exp}} = t_c$.

Pozn: $T_j^* = \min(T_j, t_c)$ a $\delta_j = I\{T_j \leq t_c\}$, $\forall j \in \hat{n}$.

V: Necht $(T_j)_1^m$ iid $F \triangleq \text{ASR}(f)$; $T_{(1)} < \dots < T_{(r)}$,
 kde $r \in \{0, 1, \dots, m\}$ je náhod. veličinou. Pak pro
 každé $0 < t_{(1)} < \dots < t_{(r)} < t_c$ je sdružená hustota

$$f_{\mathbf{I}}(t_{(1)}, \dots, t_{(r)}, r) = \frac{m!}{(m-r)!} \left[\prod_{j=1}^r f(t_{(j)}) \right] \cdot R(t_c)^{m-r}$$

a podmíněná hustota

$$f_{\mathbf{I}}(t_{(1)}, \dots, t_{(r)} | r) = \frac{r!}{F^r(t_c)} \prod_{j=1}^r f(t_{(j)}) = r! \prod_{j=1}^r \frac{f(t_{(j)})}{F(t_c)}.$$

Pozn: $\frac{f(t_{(j)})}{F(t_c)}$, $t_{(j)} < t_c$, je hustota usknutého $f_T | T < t_c$.
 rozdělení F_T v t_c

Př: $T \sim \text{Exp}(\lambda)$, Π replikace, type **I** censoring (t_c).

$$L_{\mathbf{I}}(\lambda | t_{(1)} < \dots < t_{(n)}, n) = L(\lambda | \text{data}) =$$

$$= \frac{n!}{(n-r)!} \lambda^r e^{-\lambda \sum_{j=1}^r t_{(j)}} e^{-\lambda (n-r)t_c}$$

$$\partial_{\lambda} \log L = \frac{r}{\lambda} - \sum_{j=1}^r t_{(j)} + (n-r)t_c = 0$$

$$\hat{\lambda}_{ML} = \frac{r}{\sum_{j=1}^r t_{(j)} + (n-r)t_c} = \frac{r}{T(t_c)} = \left(\frac{T(t_c)}{r} \right)^{-1}$$

TTT $\approx t_c$
total time
in test

Pozn: Cenzorování typu **I** je ekv. úplnému iid rozsahu n z $F_T | T < t_c$

Př: $T \sim \text{Weib}(\alpha, \lambda)$; $R_T(t) = e^{-(\lambda t)^\alpha}$; T ; t_c .

$\Downarrow$ $L(\alpha, \lambda | \text{data } t_{(1)} < \dots < t_{(n)}, n) = \dots$

$\Downarrow$ $\partial_\lambda \log L = 0 \quad \wedge \quad \partial_\alpha \log L = 0$ vede na

$$\hat{\lambda}_{ML} = \left(\frac{n}{\sum_1^n t_{(j)}^{\hat{\alpha}} + (n-n)t_c^{\hat{\alpha}}} \right)^{1/\hat{\alpha}} = \left(\frac{\hat{I}_\alpha(t_c^{\hat{\alpha}})}{n} \right)^{-1/\hat{\alpha}},$$

kde $\hat{\alpha}$ je numerickým (či jiným, např. WPP $\hat{\alpha}_0$)

řešením:

$$\partial_\alpha \log L = \frac{1}{\alpha} + \frac{1}{n} \sum_1^n \ln t_{(j)} - \frac{\sum_1^n t_{(j)}^\alpha \ln t_{(j)} + (n-n)t_c^\alpha \ln t_c}{\sum_1^n t_{(j)}^\alpha + (n-n)t_c^\alpha} = 0!$$

(ln L)

Type II - CENZOROVÁNÍ PORUCHOU (n)

Experiment ukončen po dosažení n -té poruchy!
($1 \leq n \leq m$)

Struktura dat: $T_{(1)}, T_{(2)}, \dots, T_{(n)}$, kde n pevné

a čas ukončení experimentu $T_{\text{exp}} = T_{(n)}$ je náhod. velič.!

& navíc info, že zbývajících $(m-n)$ poruch $T_{(n+1)}, \dots$
 $\dots, T_{(m)}$ překročilo čas konce experimentu $t_{\text{exp}} = t_{(n)}$.

Pozn: $T_j^* = \min(T_j, T_{(n)})$ a $\delta_j = I\{T_j \leq T_{(n)}\}$, $\forall j \in \hat{n}$.

V: Necht $(T_j)_1^m$ iid $F \propto ASR(f)$; $1 \leq r \leq m$;

$T_{(1)} < T_{(2)} < \dots < T_{(r)}$. Pak sdružená hustota je

$$f_{II}(t_{(1)}, \dots, t_{(r)}) = \frac{m!}{(m-r)!} \left[\prod_{j=1}^r f(t_{(j)}) \right] \cdot R(t_{(r)})^{m-r}$$

pro každé $0 < t_{(1)} < \dots < t_{(r)} < \infty$.

Pozn: $m=r \Rightarrow f_{II}(t_{(1)}, \dots, t_{(m)}) = m! \cdot \prod_{j=1}^m f(t_{(j)}) \propto L_m$
ÚPLNÝ SOUBOR

Type II ($r \propto m$) je ekvivalentní setupu úplného výběru
o r pozorováních (r pevně nenáhodné)

VÝHODA setupu Type II ($\underline{r} \approx \underline{m}$):

Celkový čas experimentu je (může být) výrazně nižší pro $\underline{r}$ iskání $\underline{r}$ poruch $\underline{r}$ celkových $n > \underline{r}$ objektů, než čekání na všech $\underline{r}$ poruch $\underline{r}$ $\underline{r}$ obj.!

NEVÝHODA Type II ($\underline{r} \approx \underline{m}$):

Do experimentu nutno vložit (investovat) dalších $(n - \underline{r})$ objektů (dle financí..., času, ... zvážíme své možnosti, zda ÚS nebo Type II)

Př: $T \sim \underline{\text{Exp}}(\lambda)$, $(T_j)_1^m$ iid replikace; type II cenz. (n).

$$\begin{aligned} L_{\mathbf{I}}(\lambda | t_{(1)} < \dots < t_{(n)}) &= \frac{m!}{(m-n)!} \lambda^n e^{-\lambda \sum_1^n t_{(j)}} e^{-\lambda(m-n)t_{(n)}} \\ &\stackrel{\text{(TTT)}}{=} L_{\mathbf{I}}(t_c = t_{(n)}) \Rightarrow \hat{\lambda}_{ML} = \frac{n}{T(t_{(n)})} = \left(\frac{T(t_{(n)})}{n} \right)^{-1}. \end{aligned}$$

Př: $T \sim \underline{\text{Weib}}(\alpha, \lambda)$, type II; Pak $L_{\mathbf{I}}(\alpha, \lambda) = L_{\mathbf{I}}(t_c = t_{(n)})$
a odhady jsou $\hat{\lambda}_{ML} = (\hat{T}_{\hat{\alpha}}(t_{(n)}^{\hat{\alpha}})/n)^{-1/\hat{\alpha}}$, kde $\hat{\alpha}$ řeší

$$\frac{n}{\alpha} + \sum_1^n \ln t_{(j)} - n \cdot \frac{\sum_1^n t_{(j)}^{\alpha} \ln t_{(j)} + (m-n) t_{(n)}^{\alpha} \ln t_{(n)}}{\sum_1^n t_{(j)}^{\alpha} + (m-n) t_{(n)}^{\alpha}} = 0!$$

Type III - Censorování časem (t_c) i poruchou (r)

Experiment ukončen po dosažení času $t_c > 0$
nebo dosažení r -té poruchy ($1 \leq r \leq n$).

Struktura dat: $T_{(1)}, T_{(2)}, \dots, T_{(R)}$, kde

$$T_{(R)} = \begin{cases} t_{(r')} & , r' < r, \text{ pokud } t_{(r)} > t_c, \\ t_{(r)} & , \text{ pokud } t_{(r)} \leq t_c. \end{cases}$$

(t_c, r pevné, ale T_{exp} a R jsou náhodné vel., podle $t_c \geq t_{(r)}$)

Pozn: $T_j^* = \min(T_j, T_{(r)}, t_c)$ a $\delta_j = I\{T_j \leq \min(T_{(r)}, t_c)\}$.

Ude o speciální případ tzv.

MODELU KONKURENČNÍCH RIZIK, kdy
porucha v čase T může nastat vlivem k různých
příčin, $\delta \in \{1, 2, \dots, k\}$. Působí zde tedy k rizik,
které soupeří o poruchu dané komponenty i (v sérii):



1. úspěšné riziko $\Rightarrow$ porucha/pád komponenty

$T \geq 0$ náhodná, $\delta \in k$ náhodná, i -té příčiny $\delta = j$.

ÚPLNÝ soubor DAT: $(T_i, \delta_i)_1^m \sim F_{T, \delta}$ (2D distrib.)

LIFE-TIME MODELY

KLINICKÝ VÝZKUM

[CLINICAL TRIALS]

$T \sim F_T \dots$ doba života, čas přežití, ...

$R_T(t) \stackrel{\text{ozn.}}{=} S_T(t)$ SURVIVAL function

Biologie, Medicína ... pacienti; Doprava ... řidiči;
Banky, Pojišťovny ... klienti; Průmysl ... výrobky;

!RANDOM CENSORING [RC]

$T \sim F_T \dots$ doba života (doba do poruchy)

$C \sim F_C \dots$ časový cenzor (náhodná doba ukončení experimentu)

T a C zpravidla nezávislé náh. vel.

(T, C) obvykle 2D-ASR rozdělení s marginálními hustotami pravd. f_T, f_C .

Pozn: Model konkurenčních rizik se dvěma "soupeřícími" módy – PORUCHA vs. VÝPADEK z experimentu!

$$W = T^* = \min(T, C) \quad \left. \begin{array}{l} \delta = I\{T \leq C\} \end{array} \right\} (W, \delta) \text{ spojité-diskrétní} \\ \text{2D rozdělení}$$

$$\text{ozn. } q = E\delta = \int 1 dP = 1 \cdot \underbrace{P(T \leq C)}_{\downarrow} + 0 \stackrel{\text{id}}{=} \int \int_{t \leq c} dF_T dF_C.$$

představuje pravděpodobnost zaznamenání poruchy při jednom opakování, tzn. střední podíl necenzorovaných pozorování (n.q je střední počet poruch v n-tici)

Realizace: $(T_j)_1^n \sim F_T$; $(C_j)_1^n \sim F_C$; $(T_j \text{ a } C_j \text{ nezávislé})$
 $W_j = \min(T_j, C_j)_1^n$ a $\delta_j = I\{T_j \leq C_j\}$

VÝPOČTY v RC modelech:

©VK2023 KM FJFI

V: Necht' W a δ jsou náhod. veličiny vzhledem k $\lambda \times x$ (čítací) míře. Předpokl., že T a C jsou nezávislé, $T \sim f_T$ a $C \sim f_C$ (ASR_λ).

Pak sdružená hustota (W, δ) vzhledem k $\lambda \times$ čít. je pro $\forall \delta, \forall w > 0$

$$f(w, \delta) = \{f_T(w)(1 - F_C(w))\}^\delta \cdot \{f_C(w)(1 - F_T(w))\}^{1-\delta}.$$

Dk:

V: Necht' $F_T = F_T(t, \theta_1)$ a $F_C = F_C(c, \theta_2)$ tak, že F_T a F_C neobsahují společné parametry, tzn. mezi θ_1 a θ_2 neexistuje funkční závislost.

Mějme $(W_j, \delta_j)_{j=1}^m$ iid $F_{W, \delta}$ REPLIKACE.

Pak $L(\theta_1, \theta_2) = f_{W, \delta}(w, \delta; \theta_1, \theta_2) = L_1(\theta_1) \cdot L_2(\theta_2)$,

kde $L_1(\theta_1) = \prod_{j \in D} f_T(w_j) \prod_{j \in V} (1 - F_T(w_j))$, kde $\Downarrow$

$L_2(\theta_2) = \prod_{j \in D} (1 - F_C(w_j)) \prod_{j \in V} f_C(w_j)$, $D = \{j : \delta_j = 1\}$, $V = \hat{m} \setminus D$.

Důsle: $\ell(\theta_1, \theta_2) = \log L = \log L_1(\theta_1) + \log L_2(\theta_2)$

$\Rightarrow$ mapř. MLE: $\partial_{\theta_1} \ell(\theta_1, \theta_2) = \partial_{\theta_1} \log L_1(\theta_1) = 0 \dots (\text{num.})$

a tedy $\hat{\theta}_{1, \text{ML}}$ lze nalézt pouze prostřednictvím $L(\theta_1)$,
stejně tak pro jiné metody MAP, Bayes,

nexávisle na θ_2 . Param. θ_2 se nazývají rušivé param.
(nuisance par.)

Pozor: Vlastnosti $\hat{\theta}_1$ ale závisí na θ_2 ,
protože mapř. $\mathbb{I}(\theta_1, \theta_2) = \begin{pmatrix} \mathbb{I}(\theta_1) & 0 \\ 0 & \mathbb{I}(\theta_2) \end{pmatrix}$ [FIM]
se vyskytne v AN (... $\mathbb{I}^{-1}(\theta_1, \theta_2)$) pro MLE odhad!

Př: (Výpočty pro RC-Exp(λ))

ozn: $D = \{j: \delta_j = 1\} \dots$ INDEXY DEFEKTŮ/poruch

$V = \{j: \delta_j = 0\} \dots$ INDEXY CENZORŮ/výpadků

$d = |D| = \sum_{j=1}^n \delta_j = \#D \dots$ počet PORUCH
v n -tici pozorov.

$T \sim \text{Exp}(\lambda)$ a $C \sim F_C(\theta_2)$ libovolné rozdělení.

$$\begin{aligned} \text{Pak } L_1(\lambda) &= \prod_{j \in D} f_T(w_j) \prod_{j \in V} R_T(w_j) = \prod_{j \in D} \lambda e^{-\lambda w_j} \prod_{j \in V} e^{-\lambda w_j} = \\ &= \lambda^{\sum_{j=1}^n \delta_j} e^{-\lambda \sum_{j=1}^n w_j} = \underline{\underline{\lambda^d \cdot e^{-\lambda w}}}, \quad w \stackrel{\text{ozn.}}{=} \sum_{j=1}^n w_j. \end{aligned}$$

a) MLE: $l_1(\lambda) = \ln L_1(\lambda) = d \cdot \ln \lambda - \lambda \cdot w$

$$\partial_\lambda l_1 = \frac{d}{\lambda} - w = 0 \Rightarrow \hat{\lambda}_{ML} = \frac{d}{w} = \frac{\sum_1^m \delta_j}{\sum_1^m w_j}.$$

Tedy $\hat{\lambda}_{ML}(W, \delta) = \frac{\bar{\delta}_m}{\bar{W}_m}$ (a je konzistentním a AN odhadem λ).

Pozn: Cenzorování typu I časem t_c je speciálním případem RC pro $C_j = t_c$, $\forall j \in \hat{n}$. Pak opravdu

$$\hat{\lambda}_{ML}^I = \frac{\sum_1^r \delta_j}{\sum_1^r w_j} = \frac{r}{\sum_1^r t_{(j)} + (n-r)t_c}, \quad \text{protože } t_{(j)} = w_{(j)} \quad \forall j \leq r, \text{ a } w_{(j)} = t_c, \forall j > r.$$

$\hat{\lambda}_{ML}^{II}$ stejně, jen záměna t_c za $t(r)$!

b, Bayesovsky odhad $\hat{\lambda}_B$, resp. $\hat{\lambda}_{MAP}$:

©11/123

Volme conjugated fam. (CF): $\pi(\lambda) = \text{gamma}(\alpha, \beta)$,

$$\text{fxn. } \pi(\lambda) = \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta \cdot \lambda} ; \alpha, \beta > 0 ; \lambda > 0.$$

$$\text{Pak } \pi(\lambda | (w, d)) = \frac{L(\lambda, \theta_2) \cdot \pi(\lambda)}{\int_0^\infty L(\lambda, \theta_2) \cdot \pi(\lambda) d\lambda} = \frac{L_1(\lambda) \cdot \pi(\lambda)}{\int L_1(\lambda) \cdot \pi(\lambda) d\lambda} =$$

$$\frac{1}{c} \lambda^d \cdot e^{-\lambda w} \cdot \lambda^{\alpha-1} \cdot e^{-\beta \lambda} \sim \text{gamma}(w + \beta, d + \alpha)$$

$$\text{a tedy: } \hat{\lambda}_B \stackrel{(L_2)}{=} E^{\pi}(\lambda | (w, d)) = \frac{d + \alpha}{w + \beta} = \frac{\bar{d}_n + d/n}{\bar{w}_n + \beta/n} !$$

$(\hat{\lambda}_{MAP} = \arg\max_{\lambda} \text{gamma}(\dots))$

V: (VLASTNOST! AN pro $\hat{\lambda}_{ML}$ a $\hat{\lambda}_B$ při RC)

Při libovolném rozdělení časového cenzoru C , platí

$$\sqrt{n}(\hat{\lambda}_{ML,B} - \lambda) \xrightarrow{D} N(0, \lambda^2 / \underline{P(T \leq C)})$$

tzv. $\hat{\lambda}_{ML,B} \sim AN(\lambda, \frac{1}{n} \lambda^2 / q)$, kde $q = E\delta = P(T \leq C)$!

a tedy $\hat{\lambda}_{ML,B}$ je ' $\sqrt{n}$ '-KONZISTENTNÍ odh. λ .

Dk: (princip) $\sqrt{n}(\hat{\lambda}_{ML} - \lambda) = \sqrt{n}\left(\frac{\bar{\delta}_n}{\bar{w}_n} - \lambda\right) = \sqrt{n}\left(\frac{\bar{\delta}_n - \lambda \bar{w}_n}{\bar{w}_n}\right),$

kdy dle CLT: $\bar{\delta}_n - \lambda \bar{w}_n \sim AN(E(\delta - \lambda W), \frac{1}{n} D(\delta - \lambda W))$

a dle ZVČ: $\bar{w}_n \xrightarrow{P} EW = \frac{1}{\lambda} E\delta = \frac{1}{\lambda} P(T \leq C)$. [SLUTSKY]

Důst: (Odhad FR $\lambda_T(t)$ a spolehlivosti $R_T(t)$)

$$\hat{\lambda}_T^{ML}(t) = \lambda_T(t, \hat{\lambda}_{ML}) = \hat{\lambda}_{ML} = \bar{d}_m / \bar{w}_m \sim AN(\lambda, \frac{1}{m} \dots), \forall t.$$

$$\hat{R}_T^{ML}(t) = R_T(t, \hat{\lambda}_{ML}) = e^{-\hat{\lambda}_{ML} t} = e^{-t \cdot \bar{d}_m / \bar{w}_m}, \forall t.$$

Delta (∇) metoda ($g(\lambda) = e^{-\lambda t}$, $g'(\lambda) = -t e^{-\lambda t}$; t fix, spoj.)

$$\Rightarrow \hat{R}_T^{ML}(t) \sim AN(\bar{e}^{-\lambda t}, \frac{1}{n} [g'(\lambda)]^2 \cdot \lambda^2 / P(T \leq c)) =$$

$$= AN(R_T(t), \frac{1}{n} [\overset{\hat{\lambda}_{ML}}{\lambda} t \overset{\hat{R}_T^{ML}(t)}{R_T(t)}]^2 / \underbrace{P(T \leq c)}_{\hat{q} = d/m}).$$

Use asympt. interval spolehlivosti pro $R_T(t)$ při $\hat{\sigma}_{ML}^2$ asym.

? Jde totéž udělat i pro Bayesovský odhad $\hat{\lambda}_B$ a $\hat{R}_B(t)$?

Amo, ALE: $\hat{\lambda}_T^B(t) = \hat{\lambda}_B = \frac{\bar{\sigma}_m + \alpha/m}{\bar{w}_m + \beta/m} \sim AN(\dots, \dots), \forall t,$

ale $\hat{R}_T(t) = R_T(t, \hat{\lambda}_B) = e^{-\hat{\lambda}_B t} = e^{-t \frac{\bar{\sigma}_m + \alpha/m}{\bar{w}_m + \beta/m}} \sim AN, \forall t,$

↓ tento odhad $\hat{R}_T(t)$ nemí (nemusí být) Bayesovským
odhadem $\hat{R}_T^B(t)$ [nefunguje zde INVARIANCE!]

Postup: $\pi(\lambda) = \text{gamma}(\alpha, \beta) \Rightarrow$ transformace $\pi(\lambda)$ na $\pi(x)$, kde $x = e^{-\lambda \cdot t_0}$; t_0 fix (apriorní info pro R_T).
Poté apost. $\pi(x | w, \sigma) \Rightarrow \hat{R}_B(t_0) \stackrel{L_2}{=} E^\pi(x | w, \sigma)$!

VÝPOČTY pro RC-Weib(α, λ)

$T \sim \text{Weib}(\alpha, \lambda)$; $C \sim F_C(\theta_2)$ libor. rozděľ.

$(W_j, \delta_j)_1^m$ iid replikace $\rightarrow \mathcal{D}, V, d = \sum_1^m \delta_j$.

$\Downarrow$

$$R_T(t) = e^{-(\lambda t)^\alpha} = e^{-\lambda^\alpha t^\alpha} = / \lambda^\alpha = \lambda' / \text{ozn. param.} = e^{-\lambda' t^\alpha}$$

$$\underline{f_T(t) = \lambda' \alpha t^{\alpha-1} e^{-\lambda' t^\alpha}} ; \lambda' > 0, \alpha > 0, t > 0.$$

$\Downarrow$

$$L_1(\alpha, \lambda') = \prod_{j \in \mathcal{D}} f_T(w_j) \prod_{j \in V} R_T(w_j) =$$

$$= \prod_{j \in D} \lambda^\alpha w_j^{\alpha-1} e^{-\lambda w_j^\alpha} \prod_{j \in V} e^{-\lambda w_j^\alpha} = \left/ \begin{array}{l} w_\alpha = \sum_1^m w_j^\alpha \\ \mu = \prod_{j \in D} w_j \end{array} \right/$$

$$= \lambda^d \alpha^d \mu^{\alpha-1} e^{-\lambda w_\alpha}$$

$$\leftarrow [\lambda = \sqrt[\alpha]{\lambda'}] \rightarrow$$

MLE: $\ell_1(\alpha, \lambda') = d \ln \lambda' + d \ln \alpha + (\alpha-1) \ln \mu - \lambda' w_\alpha$

$$\partial_{\lambda'} \ell_1 = d/\lambda' - w_\alpha = 0 \Rightarrow \hat{\lambda}'_{ML} = d/w_\alpha = \frac{\sum \delta_j}{\sum w_j^\alpha} = \frac{\bar{\delta}_m}{\overline{w_m^\alpha}}$$

$$\partial_\alpha \ell_1 = d/\alpha + \ln \mu - \lambda' \sum w_j^\alpha \ln w_j = 0 \quad \leftarrow \text{dosazením}$$

$\hat{\alpha}_{ML}$ řešením: $d/\alpha + \sum \ln w_j - d \cdot \frac{\sum_1^m w_j^\alpha \ln w_j}{\sum_1^m w_j^\alpha} = 0$

počáteční řešení $\hat{\alpha}_0 \propto WPP = \{ \ln w_{ij}, \ln(-\ln \hat{R}_{KM}(w_{ij})) \}_{j \in D}$
 kde $\hat{R}_{KM}$ je vhodný neparametrický odhad R_T při RC!

Lze spočítat Fisherovu informační matici FIM?

$$\partial^2 \log L(\alpha, \lambda, \theta_2) = \underline{\partial^2 \log L_1(\alpha, \lambda)} + \partial^2 \log L_2(\theta_2)$$

$$\partial^2 \log L_1(\alpha, \lambda) = \begin{pmatrix} (d/\lambda^{1/2}) \cdot \sum_1^m w_j^\alpha \ln w_j & 0 \\ 0 & (d/\lambda^{1/2}) + \lambda \cdot \sum_1^m w_j^\alpha (\ln w_j)^2 \end{pmatrix}$$

ale nelze explicitně spočítat $-E[\partial^2 \log L_1(\alpha, \lambda)]$

a tedy nelze použít numerickou Fisher scoring method.

Ale lze užít Newton-Raphson scoring s $\partial^2 \log L_1$!
Nebo lze Rao-Score test $H_0: \alpha=1$ (Exp) vs. $H_1: \text{IFR} \vee \text{DFR}$.

* Asymptotické vlastnosti: $\hat{\alpha}_{ML}, \hat{\lambda}_{ML}, \hat{\lambda}_{ML} = \frac{\hat{\alpha}_{ML}}{\hat{\lambda}_{ML}} \sqrt{\hat{\lambda}_{ML}^{-1}},$
 $\hat{R}_T^{ML}(t) = R_T(t, \hat{\alpha}_{ML}, \hat{\lambda}_{ML}) = e^{(\hat{\lambda}_{ML} t)^{\hat{\alpha}_{ML}}},$

obtěžně zjistitelné + závisí na rozdělení $C \sim F_C(\Theta_2).$

* Bayesovské odhady? $\pi(\alpha, \lambda) = \pi(\alpha) \cdot \pi(\lambda),$
 kde např. $\pi(\alpha) \sim U(a, b)$ a $\pi(\lambda) \sim \text{Gamma}(\tilde{\alpha}, \tilde{\beta}).$

Pak lze získat např. $(\hat{\alpha}_{MAP}, \hat{\lambda}_{MAP}) = \underset{\alpha, \lambda}{\operatorname{argmax}} \pi(\alpha) \pi(\lambda) L_1(\alpha, \lambda).$

Pozn: Cenzorováni I časem (t_c) pro $w_{(j)} = t_{(j)}, \forall j \leq n,$

$$w_{(j)} = t_c, \forall j > n.$$

$\Downarrow$
Cenzorováni II poruchou (r) záměnou t_c za $t_{(r)}$!

KOZIOL-GREENŮV model RC

@VK2023 KMFJF1

Nechť je dán spolehlivostní model $T \sim R_T$ a
pro časový cenzor C platí, že T a C nezávislé
a necht' $\exists \eta > 0$, že $R_C(t) = [R_T(t)]^\eta, \forall t > 0$.

Koziol - Greenův model!

Př: $T \sim \text{Exp}(\lambda) \wedge R_T(t) = e^{-\lambda t} \Rightarrow R_C(t) = e^{-\eta \lambda t} \sim \text{Exp}(\eta \lambda)$.

$T \sim \text{Weib}(\alpha, \lambda) \wedge R_T(t) = e^{-(\lambda t)^\alpha} \Rightarrow R_C(t) = e^{-\eta^\alpha (\lambda t)^\alpha}$

$T \sim R_T = e^{-\lambda h(t)}$ totéž...

Weib $(\alpha, \lambda \cdot \eta^{1/\alpha})$

V: (Koxiol-Green (1992)) Mějme model RC,

$$\text{Axn. } W = \min(T, C) \quad \text{a} \quad \delta = I\{T \leq C\}.$$

Pak $(\exists \eta > 0)(R_C = R_T^\eta) \Leftrightarrow$ W a δ jsou nezávislé n.v.

V: K-G. model je RC model s proporcionálními FR!

Dk: $f_C(t) = -R'_C(t) = \eta(-R'_T)R_T^{\eta-1} = \eta f_T R_T^{\eta-1}$ a tedy

$$\lambda_C(t) = f_C / R_C = \eta f_T R_T^{\eta-1} / R_T^\eta = \eta \cdot \lambda_T(t). \quad \text{Pak}$$

$$\boxed{\lambda_T(t) = 1/\eta \cdot \lambda_C(t)} \quad \text{a dále} \quad \Lambda_T = \int_0^t \lambda_T dt' = 1/\eta \cdot \Lambda_C.$$

Pozn: Obecněji COX PH: $\lambda_T(t) = \Psi(x) \cdot \lambda_0(t)$; $\times$ nezávějící doprovodné proměnné

VÝPOČTY N K.-G.M. (RC)

©VK 2023 KMFJFI

Lemma: Střední podíl necenzorovaných pozorování
 $q = E\delta = P(T \leq c) = \frac{1}{1+p} \in (0,1).$

$$\begin{aligned} \underline{Dk}: E\delta = P(T \leq c) &\stackrel{\text{nd}}{=} \iint_{t \leq c} dF_T dF_c = \int_0^\infty dF_T \int_t^\infty dF_c = \\ &= \int_0^\infty R_c(t) dF_T = \int_0^\infty R_T^{\delta}(t) dF_T = \left/ \begin{array}{l} F_T(t) = u \\ dF_T(t) = du \end{array} \right/ = \\ &= \int_0^1 (1-u)^{\delta} du = \frac{1}{1+p} \stackrel{\text{ozn.}}{=} q \end{aligned}$$

Dosažením K-G.M. do obecné $f(w, \delta) \sim$ RC modelu :

$$\begin{aligned} f(w, \delta) &= \{f_T(1-F_c)\}^\delta \cdot \{f_c(1-F_T)\}^{1-\delta} = (f_T R_c)^\delta (f_c R_T)^{1-\delta} = \\ &= (f_T R_T^\beta)^\delta (p f_T R_T^{\beta-1} R_T)^{1-\delta} = f_T R_T^\beta p^{1-\delta}; \delta=0,1. \end{aligned}$$

Důs.: $(W_j, \delta_j)_1^m$ iid replikace $\Rightarrow$

$$\begin{aligned} f(w, \delta) = L &= \prod_{j=1}^m f_T(w_j) R_T^\beta(w_j) p^{1-\delta_j} = \\ &= \left[\prod_{j=1}^m f_T(w_j) R_T^\beta(w_j) \right] \cdot p^{m-d}; \quad d = \sum_j \delta_j. \end{aligned}$$

Aplikace: $l(\theta_1) = \log L \Rightarrow$ MLE $\hat{\theta}_1$: $\frac{\partial}{\partial \theta_1} l = 0$.
(p neznáme $\Rightarrow$ navíc $\frac{\partial}{\partial p} l(\theta_1, p) = 0$) (přiznáním p) $\nearrow$

NEPARAMETRICKÉ ODHADY

© VK 2023
KM FJFI

u RC modelech

$(T, C) \dots T$ a C nezávislé; $W = T^* = \min(T, C)$
 $\delta = I\{T \leq C\}$

Zjednodušení: $(T_j, \delta_j)_1^m$ replikace (vypouštíme "*")

informace z experimentu je úplná, protože

T_j je čas poruchy ($\delta_j = 1$), jindy T_j je čas cenzoru ($\delta_j = 0$).

Uspořádaný výběr $(T_j, \delta_j)_1^m$ řadíme podle T_j !

Realizace $(t_j, \delta_j)_1^m \Rightarrow$ uspořádání $(t_{(j)}, \delta_{(j)})_1^m$.

ozn. $D = \{j : \delta_{(j)} = 1\}$... indexy všech poruch

ozn. $D_t = \{j : \delta_{(j)} = 1 \wedge t_{(j)} \leq t\}$... indexy poruch před $t > 0$


ozn. $R_t = \{i : t_{(i)} \geq t\}$... ozn. RISK SET v čase $t > 0$

ozn. indexy objektů fungujících těsně před $t > 0$

ozn. $R_{t_{(j)}} = \{i : t_{(i)} \geq t_{(j)}\}$

ozn. $n_j = \# R_{t_{(j)}} = m - j + 1$

ozn. d_j počet svázaných (ties)
poruch v čase $t_{(j)}$
 $d_j \in \{\underline{0}, 1, \dots, m\}$




KAPLAN-MEIERŮV odhad R_T/S_T :

Ozn. $\hat{p}_j = \begin{cases} \frac{n_j - 1}{n_j} = 1 - \hat{q}_j, & \text{pokud } \delta(j) = 1 \text{ [T]} \\ 1, & \text{pokud } \delta(j) = 0 \text{ [C]} \end{cases}$

Def. $\hat{R}_{KM}(t) = \prod_{j: t(j) \leq t} \hat{p}_j = \prod_{j \in D_t} \hat{p}_j = \prod_{j \in D_t} \frac{n_j - 1}{n_j} =$
 $= \prod_{j \in D_t} \frac{n - j}{n - j + 1}, \forall t > 0.$

Obecněji: $\hat{R}_{KM}(t) = \prod_{j \in D_t} \underbrace{\frac{n_j - d_j}{n_j}}_{\hat{p}_j} = \prod_{j: t(j) \leq t} \underbrace{\left(1 - \frac{d_j}{n}\right)}_{\hat{q}_j}$
 ($d_j = < 0$ nebo > 1)

$\hat{R}_{KM}$ stupňovitá "spolehlivostní" funkce, zprava spojitá,
 v každém bodě poruchy $t_{(j)}$ klesne násobkem $\hat{p}_j$,
nemění se v cenzorujících časech $t_{(j)} = c_{(j)}$ ($\delta_{(j)} = 0$),
 ale cenzor. časy $c_{(j)}$ ovlivňují hodnotu výšky skoku
 v následujícím bodě poruchy $t_{(e)}$ ($\delta_{(e)} = 1$).



Proč PRODUCT-LIMIT estimator K-M ?

$t > 0$; dělení R^+ na $\bigcup_0^\infty I_j = \bigcup_0^\infty (\mu_j, \mu_{j+1}]$; $T \sim R_T$,
 volme $t \in (\mu_m, \mu_{m+1}]$ fix. Pak součinovou pravděp.

$$R_T(t) = \underbrace{P(T > \mu_0 = 0)}_1 \cdot \underbrace{P(T > \mu_1 | T > \mu_0)}_{p_1} \cdot \underbrace{P(T > \mu_2 | T > \mu_1)}_{p_2} \cdot \dots \cdot \underbrace{P(T > \mu_m | T > \mu_{m-1})}_{p_m} \cdot \underbrace{P(T > t | T > \mu_m)}_{p_{m+1}}$$

Chceme aproximovat p_j, t_j , pomocí dostupných RC dat.

Předpokládejme, že dělení I_j je tak husté, že

$$P(\text{dvou a více událostí (T nebo C) v } I_j) \doteq \underline{\underline{0}}!$$

Ozn. poslední odlišný interval $I_{m+1}^{(1)} = (u_m, t]$.

APROXIMUJEME p_j , $\forall j \in \{1, 2, m+1\}$ takto:

$$\hat{p}_j = \begin{cases} 1, & \text{pokud žádná událost } (T \text{ ani } C) \cap I_j \\ 1, & \text{pokud pouze cenzor } (1 \times C) \cap I_j, \\ & \text{protože předp., že ten cenzurovaný objekt} \\ & \text{ještě vydrží do konce mini-intervalu } I_j. \\ \frac{n_j - 1}{n_j}, & \text{resp. } \frac{n_j - d_j}{n_j} = 1 - \frac{d_j}{n_j}, & \text{pokud } \cap I_j \\ & \text{se vyskytla právě 1 porucha, resp. } d_j \text{ times,} \\ & \text{a tedy } (n_j - 1) \text{ z } n_j \text{ objektů přežilo } I_j \text{ int.} \end{cases}$$

Výsledek P-L estim. $R_T(t) = \prod_1^{m+1} \hat{p}_j = \prod_{j \in D_t} \frac{n_j - d_j}{n_j} !$

VLASTNOSTI K-M odhadu

- 1) Pokud $\delta_{(j)} = 1, \forall j \in \hat{m}$, pak $\hat{R}_{KM}(t) = R_m(t) [ERF]$
- 2) Pokud poslední čas $t_{(m)}$ je cenzurovaný, pak nespadne na nulu a je non bona-fide odhadem $R_T(t)$.
- ! 3) $\hat{R}_{KM}(t)$ je KONZISTENTNÍM odhadem $R_T(t)$, $\forall t$.
- 4) $\hat{R}_{KM}$ je neparametrickým MLE ODHADEM R_T ,
 Azm. dosahuje $\arg\max_{R \in \mathcal{Y}} L(R)$ přes všechny funkce
 $R \in \mathcal{Y}$ s po částech stupňovitými průběhy se skoky
 v bodech poruch $t_{(j)}$ (ukázal Kaplan & Meier (1958)).

!5) Pro $\forall t > 0$ je $\hat{R}_{KM}(t) \sim AN(R_T(t), \underbrace{\frac{1}{n} R_T^2(t) \int_0^t \frac{dF_u(u)}{(1-H(u))^2}}_{\sigma_{as.}^2})$,

kde $F_u(t) = F(t, 1) = P(T \leq t, \delta = 1)$

a $H(t) = P(T < t)$.

Dokázali Breslow & Crowley (1974).

!6) Pro asymptotický rozptyl $\sigma_{as.}^2(\hat{R}_{KM}(t))$ K-M odhadu přibližně platí (odhad) GREENWOODOVA FORMULE

$$\hat{\sigma}_{as.}^2(\hat{R}_{KM}) = \hat{R}_{KM}^2(t) \cdot \sum_{j \in \mathcal{D}_t} \frac{d_j}{n_j(n_j - d_j)} \quad !!$$

Tedy lze sestavit asympt. $(1-\alpha/2)$ konfidenční interval pro R_T !

KM odhad KUMULATIVNÍ FR(Λ_T)

připomenutí: CFR $\Lambda_T(t) = -\ln R_T(t) = \int_0^t \lambda_T(t') dt'$

$$\begin{aligned}\hat{\Lambda}_{KM}(t) &= \text{MLE invariant} = -\ln \hat{R}_{KM}(t) = -\ln \prod_{j \in D_t} \hat{p}_j = \\ &= \left| \hat{p}_j = \frac{m_j - 1}{m_j} = 1 - \frac{1}{m_j} \right| = -\sum_{j \in D_t} \ln \left(1 - \frac{1}{m_j} \right) = \left| \begin{array}{l} \ln(1+x) = \sum_{n=1}^{\infty} (-1)^{n+1} \frac{x^n}{n} \\ \ln(1-x) = -\sum_{n=1}^{\infty} \frac{x^n}{n} \end{array} \right|\end{aligned}$$

$$= \sum_{j \in D_t} \left(\frac{1}{m_j} + \frac{1}{2m_j^2} + \frac{1}{3m_j^3} + \dots \right)$$

$\Rightarrow$ vhodná APROXIMACE ($\overset{1,2,3}{\underset{\dots}{\text{řadu}}})$

NELSON-AALENŮV odhad Λ_T a R_T :

©VK 2023 KM FJFI

$$\hat{\Lambda}_N(t) = \sum_{j \in \mathcal{D}_t} \frac{1}{n_j} = \sum_{j \in \mathcal{D}_t} \frac{1}{n - j + 1} = \sum_{j: t_j \leq t} \frac{d_j}{n - j + 1}$$

Aedy jde o aproximaci 1. řádu v rozvoji $\hat{\Lambda}_{KM}(t)$

$$\hat{R}_N(t) = e^{-\hat{\Lambda}_N(t)} = e^{-\sum_{j \in \mathcal{D}_t} \frac{1}{n - j + 1}}$$

je Nelsonův (1969) alternativní odhad $R_T(t)$,
který může mít v některých situacích jemně
nižší MSE než $\hat{R}_{KM}(t)$ [Fleming & Harrington (1979)]

SAMOSTATNÉ ZDŮVODNĚNÍ N-A odhadu

$\bigcup_0^\infty I_j = \bigcup_0^\infty (\mu_j, \mu_{j+1}]$ husté dělení R^+ ; $T \sim R_T$.

Volme $t \in (\mu_m, \mu_{m+1}]$ fixed. Pak stejně jako u K-M: ($\mu_{m+1} \triangleq t$ redef.)

$$\begin{aligned} \Lambda_T(t) &= -\ln R_T(t) = -\ln \prod_{j=0}^m P(T > \mu_{j+1} | T > \mu_j) = \\ &= -\sum_{j=0}^m [\ln R(\mu_{j+1}) - \ln R(\mu_j)] = \left| \begin{array}{l} \text{předp. cFR } \lambda_j \\ \text{v rámci intervalu } I_j \end{array} \right| \\ &= -\sum_{j=0}^m [\ln e^{-\lambda_j \mu_{j+1}} - \ln e^{-\lambda_j \mu_j}] = \left| \begin{array}{l} R_j(u) = e^{-\lambda_j u} \\ \lambda_j(u) = \lambda_j \text{ konst.} \end{array} \right| \\ &= \sum_{j=0}^m \lambda_j (\mu_{j+1} - \mu_j) \end{aligned}$$

Odhadneme λ_j z RC dat za předp. $P(\geq 2 \text{ události v } I_j) = 0$

$$\hat{\lambda}_j = \begin{cases} 0 & \text{pokud žádná událost nebo pouze} \\ & \text{1 cenzorující čas (C) v } I_j, \\ 1 & \text{1 porucha} \end{cases} \sim \frac{1}{n_j(u_{j+1} - u_j)} \sim \frac{1}{\text{celkový čas } n_j \text{ objektů v } I_j}$$

pokud v I_j nastala 1 porucha.

Došadíme aproximaci $\hat{\lambda}_j$ a dostaneme

$$\underline{\underline{\hat{L}_N(t) = \sum_{j=0}^m \hat{\lambda}_j (u_{j+1} - u_j) = \sum_{j \in D_t} \frac{1}{n_j} = \sum_{j \in D_t} \frac{1}{n - j + 1}}}$$

$$\hat{R}_N(t) = e^{-\hat{L}_N(t)} \quad (\underline{\underline{\text{Nelson-Aalen}}})$$

NELSON-AALEN HAZARD PLOT

Připomínka: $L_T(t) = \int_0^t \lambda_T(t') dt' = -\ln R_T(t)$

$\lambda_T(t)$ rostoucí (IFR) $\Leftrightarrow L_T$ konvexní



$\lambda_T(t)$ klesající (DFR) $\Leftrightarrow L_T$ konkávní

Def: N-A plot (HAZARD PLOT) je graf

$\{t_{(j)}, \hat{L}_N(t_{(j)})\}_{j \in D}$ (poruchy)

Postup: N-A plot $\rightarrow$ volba rodiny R_θ (např. Weib(α, λ))

$\rightarrow$ odhad $\hat{\theta}_{ML}$ při RC! $\rightarrow$ do téhož obr. $L_{\hat{\theta}_{ML}}(t) \rightarrow$ SHODA?



©VK'23

Protokol ke "zk" : data RC $\Rightarrow$

detekce param. modelu a srovnání s neparam.
v jednom společném obrázku!

ŠIROKÉ VYUŽITÍ $\hat{R}_{KM}$, resp. $\hat{R}_N$:

©VK 2023 KMFJFI

a) odhad $\hat{T}_{med}$: $\hat{R}_{KM}(\hat{T}_{med}) = \frac{1}{2}$

b) odhad $\hat{\mu} = \widehat{MTTF}_T$: $\hat{\mu} = \int_0^{\infty} \hat{R}_{KM}(t') dt'$

- pokud $t_{(m)}$ porucha $\Rightarrow \hat{R}_{KM}(t_{(m)}^+) = 0$
- pokud $t_{(m)}$ cenzurováno $\Rightarrow \hat{R}_{KM}(t) \neq 0$ pro $t > t_{(m)} \Rightarrow$

$\Rightarrow$ ŘEŠENÍ: redefinovat $t_{(m)}$ na poruchu (•)

nebo restrikce $\hat{\mu}_{t_0} = \int_{t_0}^{\infty} \hat{R}_{KM} dt$,

kde t_0 je např. čas poslední poruchy, ... ^{apod.}

c) Konfidenční interval pro $R_T(t)$, $\forall t > 0$,
přibližný ($\hat{\sigma}_{as.}^2$) asymptotický (AN) [GREENWOOD]

! d) detekce parametrického modelu pro $T \sim R_T$:


RC-PP plot: $\{F_0(t_{(j)}), \hat{F}_{KM}(t_{(j)})\}_{j \in D}$ (pouze poruchy)

RC-QQ plot: $\{\hat{F}_{KM}^{-1}(j/n), F_0^{-1}(j/n)\}_{j \in D}$ lze to,
ale lépe vynášet QQ plot v bodech $v_{(j)} = \hat{F}_{KM}(t_{(j)})$,
tedy $\{\hat{F}_{KM}^{-1}(v_{(j)}), F_0^{-1}(v_{(j)})\}_{j \in D}$

PP/QQ přibližně LINEAR $\Rightarrow F_0$ je dobrý kandidát!
na $T \sim F_0$.

RANDOM CENSORING TTT-plot

připomínka: $H\bar{F}^{-1}(v) = \int_0^{\bar{F}^{-1}(v)} R(t) dt$



TTT plot: $\left\{ \frac{i}{n}, \underbrace{\frac{H_m^{-1}(i/n)}{H_m^{-1}(1)}}_{T(t_{(i)}) / T(t_{(n)})} \right\}_{i=1}^n$ pomocí ERF a EDF.

ozn. $v_{(j)} = \hat{F}_{KM}(t_{(j)})$, $j \in \mathcal{D}$,

ozn. $K = \# \mathcal{D}$

RC-TTT plot: $\left\{ \frac{v_{(j)}}{v_{(K)}}, \frac{H_{KM}^{-1}(v_{(j)})}{H_{KM}^{-1}(v_{(K)})} \right\}_{j \in \mathcal{D}}$

kde $H_{KM}^{-1}(v_{(j)}) = \int_0^{t_{(j)}} \hat{R}_{KM}(t) dt = \sum_{i=1}^{j-1} (t_{(i+1)} - t_{(i)}) \cdot \hat{R}_{KM}(t_{(j)})$.

Shovnarův nástroj RC-PP/QQ/TTT/KM/NA:

- K-M plot, resp. $\hat{R}_{KM}$, citlivější na změny pro malé a střední časy, ale ne příliš citlivý v pravém tailu
 - N-A plot, resp. $\hat{I}_N$, méně citlivý na malé časy, protože je nucen začínat (cca) v $(0,0)$
 - TTT plot, resp. $\hat{H}_{KM}^{-1}(v)$, je velmi citlivý na střední časy, ale ne moc na malé a velké, nucen začít v $(0,0)$ a končí v $(1,1)$.
- ! Ale zase umí detekovat IFR model (TTT konkáv.) nebo DFR (TTT konvex.) či CFR (linear.)

SROVNÁNÍ 2 a více



PODSKUPIN (pacienti, výrobky,)

muži vs. ženy, mladí vs. starší, lék vs. placebo,
treatment 1 vs. 2, $\log WBC \in [1.2; 3) \text{ vs. } [2.3; 3.5) \text{ vs. } [3.5; 5]$
(kategorizace spojité WBC měřičiny)

A) GRAFICKY - sice subjektivní, ale
odhaluje specifické LOKÁLNÍ odchylky!
(na rozdíl od globálních statist. testů (α))

$T \sim R_T \dots 2 \text{ skupiny} \Rightarrow T \sim R_{T,1} ; T \sim R_{T,2}$

©K123



$$\hat{R}_{KM,1} \geq \hat{R}_{KM,2}$$

$$\hat{t}_{med,2} \leq \hat{t}_{med,1} \quad ?$$

$$\widehat{MTTF}_1 \geq \widehat{MTTF}_2 \quad ?$$

? KŘÍŽENÍ ?

KDE ?

JAK ?

PROC ?

$$\hat{F}_{N,1} \geq \hat{F}_{N,2} \quad ?$$

KONVEX vs. KONKÁV ?

(IFR) vs. (DFR) ?

ANDERSON.DAT Survival times in weeks (in remission) of 42 leukemia patients in clinical trial to compare treatment with placebo. Data from Freireich et al., "The effect of 6-mercaptopurine on the duration of steroid-induced remissions in acute leukemia," *Blood* **21**, 699-716, 1963.

2 = status (0 = censored, 1 = relapse)

3 = sex (1 = male, 0 = female)

$$4 = \log \text{WBC}$$

$5 = Rx$ (1 = placebo, 0 = treatment)

```
/field = (n3,2n2,n5,n2)
```

1	2	3	4	5	1	2	3	4	5	1	2	3	4	5
35	0	1	1.45	0	9	0	0	2.80	0	8	1	0	3.52	1
34	0	1	1.47	0	7	1	0	4.43	0	8	1	0	3.05	1
32	0	1	2.20	0	6	0	0	3.20	0	8	1	0	2.32	1
32	0	1	2.53	0	6	1	0	2.31	0	8	1	1	3.26	1
25	0	1	1.78	0	6	1	1	4.06	0	5	1	1	3.49	1
23	1	1	2.57	0	6	1	0	3.28	0	5	1	0	3.97	1
22	1	1	2.32	0	23	1	1	1.97	1	4	1	1	4.36	1
20	0	1	2.01	0	22	1	0	2.73	1	4	1	1	2.42	1
19	0	0	2.05	0	17	1	0	2.95	1	3	1	1	4.01	1
17	0	0	2.16	0	15	1	0	2.30	1	2	1	1	4.91	1
16	1	1	3.60	0	12	1	0	1.50	1	2	1	1	4.48	1
13	1	0	2.88	0	12	1	0	3.06	1	1	1	1	2.80	1
11	0	0	2.60	0	11	1	0	3.49	1	1	1	1	5.00	1
10	0	0	2.70	0	11	1	0	2.12	1					
10	1	0	2.96	0										


Log-Log R PLOT

© VK 2023
KMFJFI

$T \sim R_T$, $\Lambda_T = -\log R_T$. Log-log R plotem
maximálně graf: $\log(-\log R_T(t)) = \log \Lambda_T(t)$,
 $\forall t > 0$. Log-log R plot ROSTOUCÍ $\nu(-\infty, \infty)$!

Data RC $\Rightarrow$ odhad $\log(-\log \hat{R}_{KM})$ nebo $\log \hat{\Lambda}_N$ apod.

2 podskupiny 1 & 2 $\Rightarrow \hat{R}_{KM,1/2}$
 $\Rightarrow \log(-\log \hat{R}_{KM,1/2})$ a SROVNÁNÍ:



Proč používat právě log-log R ploty?

Def: 2 skupiny $\Rightarrow T \sim R_{T,1}$; $T \sim R_{T,2}$. Model se nazývá PROPORTIONAL HAZARDS (PH) model pokud $\exists \gamma > 0$, že platí $\lambda_{T,1}(t) = \gamma \cdot \lambda_{T,2}(t)$, $\forall t > 0$.
($\gamma > 0$ vyjadřuje kolikrát je vyšší/nížší riziko HR (peruchy, dožití, ...) pro 1. skupinu než pro 2. skupinu)

Pozn: Model se nazývá COXŮV PH model, pokud $\gamma = \gamma(X)$ je funkcí doprovodných vysvětlujících prom.
(Koxiál-greenův model je spec. případ PH modelu)


Důsł: $\lambda_{T,1} = j \cdot \lambda_{T,2} \Rightarrow R_{T,1} = R_{T,2}^j, \forall t > 0.$

Dk: $(\log R_{T,1})' = \frac{R_{T,1}'}{R_{T,1}} = -\lambda_{T,1} = -j \lambda_{T,2} = (j \log R_{T,2})'$

Pak $\log R_{T,1} = \log R_{T,2}^j + c$ ($c=0$ při $t=0$)


Důsł: log-log R $\Rightarrow \log(-\log R_{T,1}) =$
 $= \log(-j \log R_{T,2}) = \log j + \log(-\log R_{T,2})$

Tedy log-log R plochy jsou "PARALEL" $\rightarrow$
 a výška mezery $\log j$ vyjadřuje log-
 násobek rizika skup. 1 vs. skup. 2.



RC data pro 2 skupiny $\Rightarrow$ odhady $\hat{R}_{KM,1/2} \Rightarrow$

$\Rightarrow \log\text{-}\log \hat{R}_{KM,1/2}$ ploty:



1 & 2: PH OK

3: Křížení

!! Totéž parametricky $R_1(\hat{\theta}_1)$ vs. $R_2(\hat{\theta}_2)$ 1 & 2.

$\approx$ SHODA $\Rightarrow R_{T,1} \doteq R_{T,2}$

$\approx$ "PARALEL" $\Rightarrow R_{T,1} \doteq R_{T,2}^{\neq}$

+ ODHAD $\hat{\gamma}$!

$\approx$ KŘÍŽENÍ $\Rightarrow$ PH model
není oprávněný, riziko
má různý (různorodý)
vliv na obě podskupiny

SROVNÁNÍ 2 a více PODSKUPIN:

B) TESTOVÁNÍM ST. HYPOTÉZ při RC!

RC-testy typu $H_0: R_{T,1} = R_{T,2}$ vs. $H_1: R_{T,1} \neq R_{T,2}$

↓ nebo typu $H_0: R_{T,1} = R_{T,2}^{\neq}$ vs. $H_1: \text{žádné takové } \gamma_i > 0$
neexistuje

Rozhodnutí na základě p -hodnoty!

Sice statisticky objektivní (na hladině významn. α),
ale přeliš GLOBALNĚ založené na jedné hodnotě
testovací statistiky $\Rightarrow$ mezachytí LOKÁLNÍ anomálie!

Log-rank test (1972) $H_0: R_{T,1} = R_{T,2}$

1. skupina : $T_{(1)}, C_1 \dots$ data $(t_{1i}, \delta_{1i})_{i=1}^n$ [RC]

$$D_1 = \{i : \delta_{1i} = 1\} \text{ PORUCHY}$$

ozn. d_{1i} - počet svázaných poruch (ties)

$$d_{1i} = 0 \text{ (cenzor)}; i = 1 \text{ (1 porucha)}$$

$$\geq 2 \text{ (více ties poruch)}$$

2. skupina : $T_{(2)}, C_2 \dots$ data $(t_{2j}, \delta_{2j})_{j=1}^m$ [RC]

$$D_2 = \{j : \delta_{2j} = 1\}$$

ozn. d_{2j} - počet svázaných poruch (ties)

Kombinovaný soubor 1 & 2:

$(t_k, \delta_k)_{k=1}^{m+m}$... ozn. $D = \{k : \delta_k = 1\}$ **PORUCHY**

ozn. $d_k = \begin{cases} 0 & \text{cenzor v } t_k \\ 1 & \text{porucha v } t_k \end{cases}$

ozn. $n_k = \# R(t_k) \quad k \in \widehat{m+m} \geq 2$ **svázané poruchy v t_k**
(např. if $t_{1i} = t_{2j}$)

$n_{1k} = \# R_1(t_k)$ v 1. skupině

$n_{2k} = \# R_2(t_k)$ v 2. skupině

$\Downarrow$
 $d_k = d_{1k} + d_{2k}$

$$n_k = n_{1k} + n_{2k}$$

Porovnáme očekávané (expected) počty poruch s pozorovanými při H_0

$$E_1 = \sum_{k=1}^{n+m} d_k \cdot \frac{n_{1k}}{n_k} = \sum_{k \in D} d_k \frac{n_{1k}}{n_{1k} + n_{2k}} \quad (\text{EXPECTED})$$

v 1. skupině

$$V_1 = \sum_{k=1}^{n+m} d_k \cdot \frac{n_{1k} \cdot n_{2k}}{n_k^2} \quad (\text{aprox. VARIANCE } E_1 - O_1)$$

$$O_1 = \sum_j d_{1j} = \#D_1 \quad (\text{OBSERVED počty poruch})$$

v 1. skupině

Pak $\frac{O_1 - E_1}{\sqrt{V_1}} \xrightarrow{d} N(0,1)$ a $\frac{(O_1 - E_1)^2}{V_1} \xrightarrow{d} \chi^2(1)$

LOG-RANK TEST: $W_\alpha = \left\{ \frac{(O_1 - E_1)^2}{V_1} \geq \chi_{1-\alpha}^2(1) \right\}$

Pozn: Užívá se aprox. $W_\alpha = \left\{ \sum_{i=1}^2 \frac{(O_i - E_i)^2}{E_i} \geq \chi_{1-\alpha}^2(I-1) \right\}$

(std PEARSON)

Zobecnění pro $i \in I$ podskupin:

$$H_0 : R_{T,1} = R_{T,2} = \dots = R_{T,I} \text{ vs. } H_1 : \text{aspoň } 1 \neq$$

Aprox. test. statistika : $\chi^2(T) = \sum_{i=1}^I \frac{(O_i - E_i)^2}{E_i} \xrightarrow{d} \chi^2(I-1).$

Log-rank test je citlivější ve chvostu $R_{T,i}$ a nemá dostatečnou sílu testu pro případy, kdy se $R_{T,i}$ vzájemně kříží!

Citlivost na začátek $R_{T,i}$ se dá zajistit např. Peto testem (Prentice & Marek (1979)).

Doporučení :

Jako první udělat test $H_0: R_{T,1} = R_{T,2}$

(Log-rank nebo Peto nebo nějaký SW)

Pokud H_0 zamítnuta $\Rightarrow$ zkusit GRAFICKY

log-log R plot, zda $R_{T,1} = R_{T,2}^{\beta}$; $\beta > 0$.

Pokud OK, pak máme PH (proportional hazards)
a můžeme aplikovat COXův regresní model.

Pokud NOK, pak další zobecněné modely (nebo zůstat)
u $\hat{R}_{KM,1}, \hat{R}_{KM,2}$

PH COX MODEL

Semiparametrická regrese v TS

Zahrneme efekty DOPROVODNÝCH vysvětlujících veličin (tzv. KOVARIÁT) ovlivňujících dobu života objektu/subjektu/individu, ozn. je X .

- ! Treatment mode ($X_i = 0$ PLACEBO, $X_i = 1$ LÉČIVO)

DAVKA 1
DAVKA 2
- sex, věk, stav, medicínská historie, rysy prostředí, práce...
obecně stressory / zátěže / expozice / ...

Nechť $X = (X_1, X_2, \dots, X_q)$ nezávislé na čase $t > 0$.
ozn. $T \sim F_T$ baseline model při $X = 0$ odpovídající
obvykle standard. podmínkám experimentu
s baseline hazard rate $\lambda_0(t)$!

Pak PH COX model (1972) je model pro HR λ_T
ve tvaru $\lambda(t, X) = \lambda_0(t) \cdot \psi(X, \beta)$, $\forall t > 0$,
kde ψ je linkovací funkce, reprezentující
změny / vlivy kovariát X , kde
 $\psi(0, \beta) = 1$ a $\psi(X, \beta) \geq 0$, $\forall X, \forall \beta$

$\lambda_0(t)$ většinou neznámá funkce - může být
 parametrická (např. $\lambda t^\alpha \dots$ Weibull COX model)
 ale zpravidla je NEPARAMETRICKÁ, což je výhoda,
 model PH Cox je pak SEMIPARAMETRICKÝM !

$$\psi(X, \beta) = \psi(\beta \cdot X) = \begin{cases} e^{\beta X} & (\text{loglinear multiplicative}) \\ 1 + \beta X & (\text{linear additive model}) \end{cases}$$

Idete o běžnou lineární semiparametrickou regresi

$$\underline{\lambda_T(t, X)} = \lambda_0(t) \cdot e^{\beta X} \Rightarrow \ln \lambda_T = \ln \lambda_0(t) + \beta X (+ \varepsilon)$$

! ANIZ ZNÁME $\lambda_0(t)$, lze odhadovat EFEKTY/vlivy X_i !

$$L_T(t) = \int_0^t \lambda_T(t', X) dt' = \int_0^t \lambda_0(t') \cdot \psi(BX) dt' = \psi \cdot \underline{L_0(t)}$$

(L_0 nazýváme baseline CFR)

$$! R_T(t) = \bar{e}^{-L_T(t)} = (\bar{e}^{-L_0(t)})^{\psi(BX)} = (R_0(t))^{\psi(BX)}$$

(R_0 nazýváme baseline RF/SF)

pokud stressory/kovariáty nezávisí na čase $t > 0$,
pak $\psi(BX) = \text{konst.}$ a jde o model $R_T = R_0^{\beta}$.

R_T se maxímuje ADJUSTED (přizpůsobená) [K-G.M.]

spolehlivostní/survival fee při specifickovaných X
vysvětlujících doprovod. velič.

HAZARD RATIO (HR)

©WK 2023 KM

X a X^* dvě hodnoty vektorů kovariát. Pak def.

$$\begin{aligned} HR = HR(X^*, X) &= \frac{\lambda_T(t, X^*)}{\lambda_T(t, X)} = \frac{\lambda_0(t) \psi(\beta X^*)}{\lambda_0(t) \psi(\beta X)} = \\ &= \frac{\psi(\beta X^*)}{\psi(\beta X)} = \underbrace{\left| \psi() = e^{\beta X} \right|}_{\text{loglinear}} = e^{\beta(X^* - X)} \end{aligned}$$

a tedy $R_T^* = R_0^{\psi^*} = (R_T^{1/\psi})^{\psi^*} = R_T^{\psi^*/\psi} = R_T^{\text{konst.} (J^*)}$

Tedy HR vyjadřuje, kolikrát větší/menší efekt ve smyslu intenzity poruch $\lambda_T(FR)$ má setup X^* oproti X !

Pr: $X^* = (1, X_2, \dots, X_q) \dots$ PLACEBO (kontrolní skupina)

$X = (0, X_2, \dots, X_q) \dots$ LÉK (standard skupina treatment)

Pak HR = $e^{\beta(X^* - X)} = \underline{\underline{e^{\beta_1}}}$ (konst. v čase)

poměr působení efektů placebo versus treatment!

Pokud vezmeme i interakce efektů stresorů X ,

např. $X_3 = X_1 \cdot X_2 = \begin{cases} 0 \cdot X_2 = 0 \\ 1 \cdot X_2 = X_2 \end{cases}$, pak HR

může obsahovat i další regres. koef. $\beta_{i \geq 2}$.

PRAXE: Některé baseline $\lambda_0(t)$, $R_0(t)$,
Některé typ linkovací fce $\psi(B, X)$,
Některé parametry B .

DATA (experiment): $RC \dots (t_j, \delta_j)_1^n$
Odhádneme $\hat{B}$ při RC cenzurování $\Rightarrow$ HR!

$\text{loze} \Rightarrow \hat{R}_0(t)$ neparametrický odhad $R_0(t) \Rightarrow$

$$\Rightarrow \hat{R}_T(t, X) = (\hat{R}_0(t))^{\hat{B}X} \dots \text{ADJUSTED } \hat{R}_T$$

Vyhodnocení $\hat{R}_T$ v bodech t_j poruch a při X_j průměru.

Pt: $X^* = (1, X_2, \dots, X_q)$ PLACEBO (kontrolní)

$X = (0, X_2, \dots, X_q)$ LÉK (Treatment)

Data (t_j, δ_j) získána při stressorech X_j , $t_j \in \hat{n}$.

Odhad $\hat{\beta} \Rightarrow HR = f^* = e^{\hat{\beta}(\bar{X}^* - \bar{X})} = e^{\hat{\beta}_1}$

↓
Dvě křivky spolehlivosti pro každou podskupinu:

PLACEBO : $\hat{R}(t, \bar{X}) = (\hat{R}_0(t)) e^{\hat{\beta}_1 + \sum_2^q \hat{\beta}_i \bar{X}_i}$

LÉK : $\hat{R}(t, \bar{X}) = (\hat{R}_0(t)) e^{\sum_2^q \hat{\beta}_i \bar{X}_i}$ ↗ obě
ADJUSTED

VYKRESLENÍ do 1 společného OBRAZKU

+ kontrola vizuální splnění PH předp. (nekříží se)

MLE ODHAD $\hat{\beta}$

©VK2023 KMFJFI

PARTIAL LIKELIHOOD FUNCTION (PLF)

$$L_p(\beta) = \prod_{j \in D} \frac{\psi(\beta X_{(j)})}{\sum_{k \in R(t_{(j)})} \psi(\beta X_{(k)})} =$$

$$= \prod_{j=1}^n \left(\frac{\psi(\beta X_j)}{\sum_{k \in R(t_j)} \psi(\beta X_k)} \right)^{\delta_j} = \left| \psi = e^{\beta X} \right|_{\text{loglinear}}$$

$L_p(\beta)$ nezávisí přímo na $t_{(j)}$, ale pouze na $R(t_{(j)})$.
Jde o aproximaci podmíněné Pr poruchy (j) -té komponenty...

$$\begin{aligned}\ln L_P(\beta) &= \sum_{j \in D} (\ln \psi_j - \ln(\sum_{k \in R_j} \psi_k)) = \left/ \psi_j = e^{\beta x_j} \right/ \\ &= \sum_{j \in D} (\beta x_j - \ln \sum_{k \in R_j} e^{\beta x_k}) \stackrel{\text{ozn.}}{=} \sum_{j \in D} L_j(\beta)\end{aligned}$$

$$\frac{\partial}{\partial \beta_k} \ln L_P(\beta) = 0, \quad \forall k \in \hat{q}.$$

ITERAČNÍ NUMERIC. ŘEŠENÍ (SIK)

V: Za jistých podmínek regularity je $\hat{\beta}_{ML,P}$
konzistentní a AN odhad β při RC!

Následuje odhad $\hat{HR} = e^{\hat{\beta}_{ML,P}(X^* - X)}$ Pr: $e^{\hat{\beta}_{1,ML,P}}$

ODHAD BASELINE $\hat{R}_0(t)$

Breslow (1974): neparametrický odhad

$$\hat{R}_0(t) = e^{-\hat{L}_0(t)}, \text{ kde}$$

$$\hat{L}_0(t) = \sum_{j \in \mathcal{D}_t} \frac{1}{\sum_{k \in R(t_j)} \psi(\hat{\beta}_{MLP} X_k)} = \left| \psi = e^{\beta X} \right| \text{ loglinear}$$

Stupňovitý odhad se skoky v časech poruch t_j !

$$\hat{\beta} = 0 \Rightarrow \hat{\psi}_k = e^{\hat{\beta} X_k} = 1 \quad \forall k \Rightarrow \hat{L}_0(t) = \sum_{\mathcal{D}_t} 1/n_j = \hat{L}_N$$

Pokud některé kovariáty nevyhovují PH předpokladu,
pak je lze STRATIFIKOVAT, neboli KATEGORI-
ZOVAT, přeznačit opět na nové $\tilde{X}$ s $\dim \tilde{q}$.

S-COX model: $\lambda_s(t, X) = \lambda_{0s}(t) \cdot \psi(\beta_s X)$, $\forall s \in \tilde{q}$.

a) $\beta_s = \beta$, $\forall s$ (NO INTERACTIONS)
odhad $\hat{\beta} \propto \text{PLF}(\bigcap_s L_s)$ a $\hat{HR}_s = e^{\hat{\beta}(X^* - X)}$.

b) β_s různá (S INTERAKCEMI)
odhady $\hat{\beta}_s \propto \text{PLF } L_s$ "monitř každého strata", $\forall s$.

TIME DEPENDENT COVARIATES in COX

$$X = X(t) \Rightarrow \lambda(t, X(t)) = \lambda_0(t) \cdot \psi(\beta X(t))$$

např. $X_i(t) = \begin{cases} 1 & \text{pro } t < t_0 \text{ (TREATMENT 1)} \\ 2 & \text{pro } t \geq t_0 \text{ (TREATMENT 2)} \end{cases}$

nebo $X_i(t) = 1, 2, 3, \dots$ v časech $t_0, t_1, t_2, \dots$



STRESS PROCES (Accelerated Life)
Testing ALT!

nebo age(t); employment status(t); smoking status(t);
obesity level(t); air pollution index(t); EPIDEMIOLOGIE

Volba typu závislosti na t : $X_i(t) = X_i \cdot g_i(t)$

např. Δ HEAVYSIDE funkcí $g_i(t) = \begin{cases} 1, & t < t_0 \\ 0, & t \geq t_0 \end{cases}$

Používá se, pokud např. dochází ke krájení $\lambda_T^{(*)}$, apod:



01 SKE

2h/tyden

SPOLEHLIVOST A KLINICKÉ
EXPERIMENTY

KONEC části - **III**

© VK 2023 KM FJFI